MACHINE LEARNING AND APPLICATIONS

Danh sách chủ đề Bài tập lớn (Assignment)

Chương trình Thạc sĩ Khoa học Máy tính · Mô tả chủ đề, hướng dẫn thực hiện và tiêu chí đánh giá

6–8 tuần	2–3	18	≥ 2 ngày
Thời gian thực hiện	Thành viên mỗi nhóm (khuyến khích)	Chủ đề trong 6 nhóm	Nộp báo cáo trước ngày thi cuối kỳ

Mục lục

1. Giới thiệu 2

2. Tổng quan danh sách chủ đề 2

3. Mô tả chi tiết từng chủ đề 3

3.1 Nhóm I – Data Analytics 3

3.2 Nhóm II – Forecasting 5

3.3 Nhóm III – Computer Vision 6

3.4 Nhóm IV – OOD / NCD / GCD 8

3.5 Nhóm V – Continual Learning 9

3.6 Nhóm VI – Mathematical Fundamentals 10

4. Hướng dẫn thực hiện 12

4.1 Quy trình 6 bước 12

4.2 Yêu cầu về thực nghiệm 12

4.3 Yêu cầu về mã nguồn 12

4.4 Sử dụng công cụ AI 12

5. Sản phẩm nộp & tiêu chí đánh giá 13

5.1 Sản phẩm nộp 13

5.2 Rubric đánh giá (thang 10) 14

6. Lịch trình & quy định 14

6.1 Lộ trình 6–8 tuần 14

6.2 Hình thức trình bày 15

6.3 Quy định 15

1. Giới thiệu

Danh sách gồm **18 chủ đề trong 6 nhóm**, bám sát nội dung giảng dạy (regression, SVM, Neural Network, Deep Neural Network) và ba hướng ứng dụng chính: Data Analysis, Forecasting, Computer Vision.

- **Đối tượng:** học viên cao học ngành Khoa học Máy tính, làm việc theo nhóm 2–3 người (khuyến khích) trong 6–8 tuần.
- **Mục tiêu:** đọc hiểu và tái hiện (reproduce) một phương pháp từ tài liệu nghiên cứu, thực nghiệm trên benchmark chuẩn, phân tích kết quả có phản biện và đề xuất cải tiến hoặc ứng dụng.
- **Mức độ:** mỗi chủ đề có *yêu cầu tối thiểu* (đủ điểm đạt) và *hướng mở rộng* (điểm cao/bonus), để các nhóm có nền tảng khác nhau đều chọn được đề phù hợp. Yêu cầu tối thiểu đã được cân chỉnh cho nhóm 2–3 người trong 6–8 tuần.

2. Tổng quan danh sách chủ đề

Bảng dưới tóm tắt 18 chủ đề theo nhóm, mô hình liên quan trong môn học và độ khó ước lượng.

Độ khó: Trung bình Khá Khó – ước lượng tương đối để cân nhắc khi đăng ký.

#	Chủ đề	Mô hình trong môn học	Độ khó
Nhóm I – Data Analytics			
1	Interpretable regression & explainability	Linear/Logistic regression, GAM	Trung bình
2	SVM & kernel methods at scale	SVM, kernel, Logistic regression	Trung bình
3	Deep learning framework for tabular data	MLP, DNN, GBDT	Khá
Nhóm II – Forecasting			
4	Time series forecasting using machine learning	Linear models, GBDT, RNN/LSTM	Trung bình
5	Transformers & foundation models for time series forecasting	Linear, Transformer	Khó
6	Probabilistic forecasting & uncertainty quantification	Quantile regression, DNN	Khá
Nhóm III – Computer Vision			
7	CNN vs Vision Transformer for image classification	CNN, ViT	Trung bình
8	Self-supervised & transfer learning with few labels	DNN, Logistic regression (linear probe)	Khá
9	Visual anomaly detection for industrial inspection	CNN features, kNN, One-class SVM	Khá
10	Adversarial robustness of deep networks	CNN, DNN	Khó

#	Chủ đề	Mô hình trong môn học	Độ khó
Nhóm IV – OOD / NCD / GCD			
11	Out-of-Distribution Detection (OOD)	DNN	Khá
12	Novel Class Discovery (NCD)	DNN, clustering	Khó
13	Generalized Category Discovery (GCD)	DNN, ViT, clustering	Khó
Nhóm V – Continual Learning			
14	Continual learning using representation & contrastive learning	DNN	Khó
15	Continual learning with game theory	DNN	Khó
Nhóm VI – Mathematical Fundamentals			
16	Sharpness-Aware Minimization (SAM), flat minima và generalization	DNN, optimization	Khó
17	Diffusion maps	Kernel, spectral methods	Khó
18	Calibration of neural networks	Logistic regression, DNN	Trung bình

3. Mô tả chi tiết từng chủ đề

Mỗi chủ đề được trình bày thành một khối gồm: mô tả, yêu cầu tối thiểu, hướng mở rộng, dữ liệu gợi ý, tài liệu tham khảo và mã nguồn.

> **Lưu ý chung**
>
> - **Dataset:** nhóm có thể đề xuất dataset khác với gợi ý, miễn là phù hợp với bài toán đang giải.
> - **Tài liệu:** khuyến khích tham khảo thêm các tài liệu liên quan ngoài danh sách đã gợi ý, và trích dẫn đầy đủ trong báo cáo.

3.1 Nhóm I – Data Analytics

Chủ đề 1. Interpretable regression & explainability

Mô hình: Linear/Logistic regression, GAM **Độ khó:** Trung bình

Mô tả	So sánh mô hình dễ diễn giải (Linear/Logistic regression với L1/L2/Elastic Net, GAM/EBM) với mô hình hộp đen (GBDT, MLP) được giải thích bằng SHAP; phân tích đánh đổi accuracy – interpretability.
Yêu cầu tối thiểu	• Triển khai regularized regression, chọn siêu tham số bằng cross-validation. • So sánh với ít nhất một mô hình hộp đen; trình bày hệ số mô hình và SHAP values.

Hướng mở rộng	• Kiểm tra độ ổn định của giải thích (bootstrap); fairness giữa các nhóm dân số.
Dữ liệu gợi ý	UCI Adult, German Credit, MIMIC (nếu có quyền truy cập).
Tài liệu tham khảo	[1] *Regression Shrinkage and Selection via the Lasso* (Tibshirani, 1996) [2] *Regularization and Variable Selection via the Elastic Net* (Zou & Hastie, 2005) [3] *A Unified Approach to Interpreting Model Predictions* (Lundberg & Lee, 2017) – https://arxiv.org/abs/1705.07874 [4] *InterpretML: A Unified Framework for Machine Learning Interpretability* (Nori et al., 2019) – https://arxiv.org/abs/1909.09223
Mã nguồn	• https://github.com/shap/shap • https://github.com/interpretml/interpret

Chủ đề 2. SVM & kernel methods at scale

Mô hình: SVM, kernel, Logistic regression **Độ khó:** Trung bình

Mô tả	Nghiên cứu SVM tuyến tính và phi tuyến (kernel trick) cùng các kỹ thuật mở rộng cho dữ liệu lớn: Random Fourier Features, Nyström approximation, GPU SVM.
Yêu cầu tối thiểu	• So sánh SVM (linear, RBF), Logistic regression và MLP về accuracy, thời gian huấn luyện và bộ nhớ khi số mẫu tăng dần.
Hướng mở rộng	• Phân tích sai số xấp xỉ kernel theo số features; SVM trên đặc trưng trích từ mạng pretrained.
Dữ liệu gợi ý	20 Newsgroups, Covertype, MNIST/Fashion-MNIST.
Tài liệu tham khảo	[1] *Support-Vector Networks* (Cortes & Vapnik, 1995) [2] *Random Features for Large-Scale Kernel Machines* (Rahimi & Recht, NeurIPS 2007) [3] *LIBSVM: A Library for Support Vector Machines* (Chang & Lin) – https://www.csie.ntu.edu.tw/~cjlin/libsvm/
Mã nguồn	• https://github.com/Xtra-Computing/thundersvm • scikit-learn: module `kernel_approximation`

Chủ đề 3. Deep learning framework for tabular data

Mô hình: MLP, DNN, GBDT **Độ khó:** Khá

Mô tả	Đánh giá các kiến trúc deep learning cho dữ liệu bảng (MLP, ResNet, FT-Transformer, TabPFN) so với GBDT (XGBoost, LightGBM, CatBoost), có kiểm định thống kê khi so sánh.
Yêu cầu tối thiểu	• Ít nhất 2 dataset, 2 mô hình DL + 1 GBDT, cùng ngân sách tuning. • Báo cáo mean ± std qua nhiều seed.
Hướng mở rộng	• Phân tích khi nào DL thắng GBDT (kích thước dữ liệu, feature heterogeneity); thử tabular foundation model trên dữ liệu nhỏ.

Tài liệu tham khảo	[1] *PyTorch Tabular: A Framework for Deep Learning with Tabular Data* (Joseph, 2021) – https://arxiv.org/abs/2104.13638 [2] *A Closer Look at Deep Learning Methods on Tabular Datasets* (Ye et al., 2024) – https://arxiv.org/abs/2407.00956 [3] *Accurate predictions on small data with a tabular foundation model* (Hollmann et al., Nature 2025) – https://www.nature.com/articles/s41586-024-08328-6
Mã nguồn	• https://github.com/LAMDA-Tabular/Tabular-Survey

3.2 Nhóm II – Forecasting

Chủ đề 4. Time series forecasting using machine learning

Mô hình: Linear models, GBDT, RNN/LSTM **Độ khó:** Trung bình

Mô tả	Xây dựng pipeline dự báo doanh số từ baseline thống kê đến ML: seasonal naive, ARIMA, Linear regression với lag features, GBDT, LSTM.
Yêu cầu tối thiểu	• Feature engineering (lag, rolling, calendar). • Đánh giá bằng time-series cross-validation (rolling origin); báo cáo MAE/RMSE/MASE.
Hướng mở rộng	• Dự báo phân cấp (hierarchical reconciliation); ảnh hưởng của ngày lễ/khuyến mãi.
Dữ liệu gợi ý	Walmart Sales; M5 – https://www.kaggle.com/competitions/m5-forecasting-accuracy
Tài liệu tham khảo	[1] *Walmart Sales Time Series Forecasting Using Machine Learning* (GitHub project) – https://github.com/abhinav-bhardwaj/Walmart-Sales-Time-Series-Forecasting-Using-Machine-Learning

Chủ đề 5. Transformers & foundation models for time series forecasting

Mô hình: Linear, Transformer **Độ khó:** Khó

Mô tả	Kiểm chứng tranh luận "Transformer có thực sự hiệu quả cho dự báo?": so sánh mô hình tuyến tính (DLinear), Transformer (PatchTST) và foundation model zero-shot (Chronos, TimesFM).
Yêu cầu tối thiểu	• Tái hiện DLinear và PatchTST trên ít nhất 2 benchmark (ETT, Weather, Electricity), nhiều horizon.
Hướng mở rộng	• Zero-shot vs fine-tune foundation model trên dữ liệu thực tế của Việt Nam (điện năng, giá nông sản, chất lượng không khí).
Tài liệu tham khảo	[1] *Are Transformers Effective for Time Series Forecasting?* (Zeng et al., 2022) – https://arxiv.org/abs/2205.13504 [2] *A Time Series is Worth 64 Words: Long-term Forecasting with Transformers* (Nie et al., 2022) – https://arxiv.org/abs/2211.14730 [3] *Chronos: Learning the Language of Time Series* (Ansari et al., 2024) – https://arxiv.org/abs/2403.07815 [4] *A decoder-only foundation model for time-series forecasting* (Das et al., 2023) –

	https://arxiv.org/abs/2310.10688
Mã nguồn	• https://github.com/thuml/Time-Series-Library • https://github.com/amazon-science/chronos-forecasting

Chủ đề 6. Probabilistic forecasting & uncertainty quantification

Mô hình: Quantile regression, DNN **Độ khó:** Khá

Mô tả	Thay vì dự báo một điểm, ước lượng khoảng dự báo bằng quantile regression, DeepAR và conformal prediction.
Yêu cầu tối thiểu	• So sánh ít nhất 2 phương pháp theo coverage, interval width và CRPS/pinball loss.
Hướng mở rộng	• Conformal prediction cho chuỗi có distribution shift; ứng dụng vào bài toán tồn kho hoặc năng lượng.
Tài liệu tham khảo	[1] *DeepAR: Probabilistic Forecasting with Autoregressive Recurrent Networks* (Salinas et al., 2017) – https://arxiv.org/abs/1704.04110 [2] *A Gentle Introduction to Conformal Prediction and Distribution-Free Uncertainty Quantification* (Angelopoulos & Bates, 2021) – https://arxiv.org/abs/2107.07511
Mã nguồn	• https://github.com/awslabs/gluonts • https://github.com/scikit-learn-contrib/MAPIE

3.3 Nhóm III – Computer Vision

Chủ đề 7. CNN vs Vision Transformer for image classification

Mô hình: CNN, ViT **Độ khó:** Trung bình

Mô tả	So sánh inductive bias của CNN (ResNet, ConvNeXt) và ViT theo kích thước dữ liệu, data augmentation và chi phí tính toán.
Yêu cầu tối thiểu	• Fine-tune CNN và ViT pretrained trên 1 dataset (kèm huấn luyện từ đầu với một mô hình nhỏ để so sánh). • Vẽ learning curve theo % dữ liệu; trực quan hóa bằng Grad-CAM/attention map.
Hướng mở rộng	• Đánh giá robustness với corruption (CIFAR-10-C) hoặc shape/texture bias.
Dữ liệu gợi ý	CIFAR-10/100, Oxford-IIIT Pets, một bộ ảnh y tế/nông nghiệp.
Tài liệu tham khảo	[1] *Deep Residual Learning for Image Recognition* (He et al., 2015) – https://arxiv.org/abs/1512.03385 [2] *An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale* (Dosovitskiy et al., 2020) – https://arxiv.org/abs/2010.11929 [3] *A ConvNet for the 2020s* (Liu et al., 2022) – https://arxiv.org/abs/2201.03545
Mã nguồn	• https://github.com/huggingface/pytorch-image-models

Chủ đề 8. Self-supervised & transfer learning with few labels

Mô hình: DNN, Logistic regression (linear probe) **Độ khó:** Khá

Mô tả	Khai thác biểu diễn từ mô hình tự giám sát (SimCLR, DINOv2) và vision-language (CLIP) khi chỉ có ít nhãn.
Yêu cầu tối thiểu	• Linear probe (Logistic regression/SVM trên embedding), kNN và fine-tune với 1%, 10%, 100% nhãn. • So sánh với supervised baseline.
Hướng mở rộng	• Zero-shot CLIP, prompt engineering; ứng dụng vào domain có ít nhãn (ảnh y tế, bệnh cây trồng).
Tài liệu tham khảo	[1] *A Simple Framework for Contrastive Learning of Visual Representations* (Chen et al., 2020) – https://arxiv.org/abs/2002.05709 [2] *DINOv2: Learning Robust Visual Features without Supervision* (Oquab et al., 2023) – https://arxiv.org/abs/2304.07193 [3] *Learning Transferable Visual Models From Natural Language Supervision* (Radford et al., 2021) – https://arxiv.org/abs/2103.00020
Mã nguồn	• https://github.com/facebookresearch/dinov2 • https://github.com/openai/CLIP

Chủ đề 9. Visual anomaly detection for industrial inspection

Mô hình: CNN features, kNN, One-class SVM **Độ khó:** Khá

Mô tả	Phát hiện lỗi sản phẩm khi chỉ có ảnh mẫu "bình thường", dựa trên đặc trưng CNN pretrained + kNN/memory bank (PatchCore) hoặc One-class SVM.
Yêu cầu tối thiểu	• Tái hiện PatchCore và một baseline (One-class SVM hoặc autoencoder) trên MVTec AD. • Báo cáo image-level và pixel-level AUROC.
Hướng mở rộng	• Phân tích tốc độ suy luận để triển khai trên dây chuyền; liên hệ với bài toán OOD (chủ đề 11).
Tài liệu tham khảo	[1] *Towards Total Recall in Industrial Anomaly Detection* (Roth et al., 2021) – https://arxiv.org/abs/2106.08265 [2] *MVTec AD dataset* – https://www.mvtec.com/company/research/datasets/mvtec-ad
Mã nguồn	• https://github.com/openvinotoolkit/anomalib

Chủ đề 10. Adversarial robustness of deep networks

Mô hình: CNN, DNN **Độ khó:** Khó

Mô tả	Nghiên cứu tấn công đối kháng (FGSM, PGD) và phòng thủ bằng adversarial training; liên hệ

	với margin của SVM.
Yêu cầu tối thiểu	• Tấn công một CNN chuẩn trên CIFAR-10, huấn luyện lại bằng PGD adversarial training. • Báo cáo clean vs robust accuracy theo epsilon.
Hướng mở rộng	• Đánh giá bằng AutoAttack/RobustBench; phân tích đánh đổi robustness – accuracy.
Tài liệu tham khảo	[1] *Explaining and Harnessing Adversarial Examples* (Goodfellow et al., 2014) – https://arxiv.org/abs/1412.6572 [2] *Towards Deep Learning Models Resistant to Adversarial Attacks* (Madry et al., 2017) – https://arxiv.org/abs/1706.06083 [3] *RobustBench: a standardized adversarial robustness benchmark* (Croce et al., 2020) – https://arxiv.org/abs/2010.09670
Mã nguồn	• https://github.com/RobustBench/robustbench

3.4 Nhóm IV – OOD / NCD / GCD

Chủ đề 11. Out-of-Distribution Detection (OOD)

Mô hình: DNN **Độ khó:** Khá

Mô tả	Phát hiện các mẫu đầu vào nằm ngoài phân phối huấn luyện, để mô hình không đưa ra dự đoán sai với độ tự tin cao.
Yêu cầu tối thiểu	• So sánh ít nhất 3 phương pháp post-hoc (MSP, Energy, Mahalanobis/kNN) trên một cặp ID/OOD chuẩn. • Báo cáo AUROC và FPR@95.
Hướng mở rộng	• Near-OOD vs far-OOD; OOD với backbone pretrained lớn (CLIP).
Tài liệu tham khảo	[1] *Generalized Out-of-Distribution Detection: A Survey* (Yang et al., 2021) – https://arxiv.org/abs/2110.11334
Mã nguồn	• https://github.com/Jingkang50/OODSurvey (benchmark: OpenOOD)

Chủ đề 12. Novel Class Discovery (NCD)

Mô hình: DNN, clustering **Độ khó:** Khó

Mô tả	Phát hiện và phân cụm các lớp mới trong dữ liệu chưa gán nhãn, dựa trên tri thức học được từ các lớp đã biết.
Yêu cầu tối thiểu	• Tái hiện một phương pháp NCD trên CIFAR-10/100. • Đánh giá bằng clustering accuracy (Hungarian matching), so với baseline k-means trên đặc trưng.
Tài liệu tham khảo	[1] *Novel Class Discovery: an Introduction and Key Concepts* (Troisemaine et al., 2023) – https://arxiv.org/abs/2302.12028

Mã nguồn	• https://github.com/JosephKJ/Awesome-Novel-Class-Discovery

Chủ đề 13. Generalized Category Discovery (GCD)

Mô hình: DNN, ViT, clustering **Độ khó:** Khó

Mô tả	Mở rộng của NCD: dữ liệu chưa gán nhãn chứa cả lớp đã biết lẫn lớp mới; mô hình phải nhận diện lớp cũ và khám phá lớp mới cùng lúc.
Yêu cầu tối thiểu	• Tái hiện GCD với backbone ViT (DINO) trên một benchmark generic và một benchmark fine-grained. • Báo cáo accuracy cho All/Old/New classes.
Hướng mở rộng	• Ước lượng số lớp mới khi chưa biết trước.
Tài liệu tham khảo	[1] *Generalized Category Discovery* (Vaze et al., 2022) – https://arxiv.org/abs/2201.02609
Mã nguồn	• https://github.com/JosephKJ/Awesome-Novel-Class-Discovery

3.5 Nhóm V – Continual Learning

Chủ đề 14. Continual learning using representation & contrastive learning

Mô hình: DNN **Độ khó:** Khó

Mô tả	Học tuần tự nhiều tác vụ mà không quên kiến thức cũ (catastrophic forgetting), dựa trên học biểu diễn và contrastive learning.
Yêu cầu tối thiểu	• So sánh fine-tuning tuần tự, một phương pháp replay (ER) và Co2L/CCLIS trên Split CIFAR-10. • Báo cáo average accuracy và forgetting.
Tài liệu tham khảo	[1] *A Comprehensive Survey of Continual Learning: Theory, Method and Application* (Wang et al., 2023) – https://arxiv.org/abs/2302.00487 [2] *Contrastive Continual Learning with Importance Sampling and Prototype-Instance Relation Distillation* (Li et al., 2024) – https://arxiv.org/abs/2403.04599 [3] *Co²L: Contrastive Continual Learning* (Cha et al., 2021) – https://arxiv.org/abs/2106.14413
Mã nguồn	• https://github.com/lijy373/CCLIS • https://github.com/chaht01/Co2L

Chủ đề 15. Continual learning with game theory

Mô hình: DNN **Độ khó:** Khó

Mô tả	Mô hình hóa continual learning dưới góc nhìn lý thuyết trò chơi, cân bằng giữa tính ổn định

	(stability) và khả năng học mới (plasticity).
Yêu cầu tối thiểu	• Mô hình hóa đánh đổi stability–plasticity như một trò chơi. • Triển khai và so sánh với một baseline continual learning.
Tài liệu tham khảo	[1] *A Comprehensive Survey of Continual Learning: Theory, Method and Application* (Wang et al., 2023) – https://arxiv.org/abs/2302.00487 [2] *Applications of game theory in deep learning: a survey* (Hazra & Anjaria, Multimedia Tools and Applications 2022) – https://gametheory.fit.hanu.vn/wp-content/uploads/2024/03/s11042-022-12153-2-1.pdf [3] *End-to-End Learning and Intervention in Games* (Li et al., 2020) – https://arxiv.org/abs/2010.13834 [4] *What Game Are We Playing? End-to-end Learning in Normal and Extensive Form Games* (Ling et al., IJCAI 2018) – https://www.ijcai.org/proceedings/2018/0055.pdf [5] Bài báo trên OpenReview – https://openreview.net/forum?id=u1XV9BPAB9

3.6 Nhóm VI – Mathematical Fundamentals

Chủ đề 16. Sharpness-Aware Minimization (SAM), flat minima và generalization

Mô hình: DNN, optimization **Độ khó:** Khó

Mô tả	SAM được đề xuất với kỳ vọng nghiệm "phẳng" sẽ tổng quát hóa tốt hơn. Chủ đề bổ sung góc nhìn phản biện từ Schliserman, Vansover-Hager & Koren (OPT 2025): trong smooth stochastic convex optimization, cực tiểu phẳng không đảm bảo tổng quát hóa tốt. SA-ERM có thể trả về cực tiểu phẳng với population risk Ω(1) trong khi một cực tiểu nhọn lại tổng quát hóa tối ưu; SA-GD có thể đạt cực tiểu phẳng nhưng vẫn tổng quát hóa kém; SAM có thể hội tụ về cực tiểu nhọn. Nhóm cần đối chiếu các kết luận lý thuyết này với thực nghiệm trên mạng sâu.
Cập nhật SAM	$$w_{t+1} = w_t - \eta \nabla F_S\left(w_t + r\frac{\nabla F_S(w_t)}{\|\nabla F_S(w_t)\|}\right)$$ *Bán kính r, learning rate η, empirical loss F_S trên tập huấn luyện S.*
Yêu cầu tối thiểu	• **Lý thuyết:** trình bày SA-ERM, SA-GD, SAM và định nghĩa ρ-flatness; tóm tắt và giải thích trực quan các định lý chính của paper OPT 2025 (không yêu cầu chứng minh lại). • **Thực nghiệm:** so sánh SGD với SAM và một biến thể (ASAM hoặc F-SAM) trên CIFAR-10 với một ResNet nhỏ; đo sharpness (top Hessian eigenvalue hoặc m-sharpness), test accuracy và generalization gap qua ít nhất 3 seed. • **Phân tích:** sharpness có tương quan nhất quán với generalization gap không, và kết quả thực nghiệm phù hợp hay mâu thuẫn với kết luận lý thuyết ở điểm nào.
Hướng mở rộng	• Mô phỏng số một bài toán convex nhỏ (ví dụ hồi quy tuyến tính/logistic nhiều chiều, ít mẫu) để minh họa trường hợp cực tiểu phẳng nhưng tổng quát hóa kém. • Khảo sát ảnh hưởng của bán kính r và learning rate η; thảo luận vì sao kết luận trong convex có thể khác với deep learning.
Tài liệu tham khảo	[1] *Flat Minima and Generalization: Insights from Stochastic Convex Optimization* (Schliserman, Vansover-Hager & Koren, OPT 2025) – https://opt-ml.org/papers/2025/paper53.pdf (arXiv: https://arxiv.org/abs/2511.03548)

	[2] *Sharpness-Aware Minimization for Efficiently Improving Generalization* (Foret et al., 2020) – https://arxiv.org/abs/2010.01412 [3] *Friendly Sharpness-Aware Minimization* (Li et al., 2024) – https://arxiv.org/abs/2403.12350 [4] *When Do Flat Minima Optimizers Work?* (Kaddour et al., 2022) – https://arxiv.org/abs/2202.00661
Mã nguồn	• https://github.com/google-research/sam • https://github.com/nblt/F-SAM

Chủ đề 17. Diffusion maps

Mô hình: Kernel, spectral methods **Độ khó:** Khó

Mô tả	Phương pháp giảm chiều phi tuyến dựa trên quá trình khuếch tán (random walk) trên đồ thị dữ liệu, bảo toàn cấu trúc hình học của manifold.
Yêu cầu tối thiểu	• Triển khai diffusion maps, so sánh với PCA, kernel PCA, t-SNE/UMAP trên dữ liệu tổng hợp (Swiss roll) và dữ liệu thật. • Phân tích ảnh hưởng của kernel bandwidth.
Tài liệu tham khảo	[1] *Diffusion maps* (Coifman & Lafon, Applied and Computational Harmonic Analysis 2006) – https://www.sciencedirect.com/science/article/pii/S1063520306000546 [2] *A Survey of Geometric Optimization for Deep Learning: From Euclidean Space to Riemannian Manifold* (Fei et al., ACM Computing Surveys 2025) – https://dl.acm.org/doi/epdf/10.1145/3708498 [3] *Deep Diffusion Maps* (García-Heredia et al., 2025) – https://arxiv.org/abs/2505.06087

Chủ đề 18. Calibration of neural networks

Mô hình: Logistic regression, DNN **Độ khó:** Trung bình

Mô tả	Mạng sâu hiện đại thường quá tự tin. Chủ đề nối Logistic regression (Platt scaling) với DNN (temperature scaling), đồng thời giới thiệu hiện tượng double descent.
Yêu cầu tối thiểu	• Đo ECE và vẽ reliability diagram cho Logistic regression, MLP, ResNet. • Áp dụng temperature scaling và ít nhất một phương pháp khác (label smoothing, MC Dropout hoặc deep ensembles).
Hướng mở rộng	• Calibration dưới distribution shift; quan hệ giữa độ rộng mô hình, double descent và calibration.
Tài liệu tham khảo	[1] *On Calibration of Modern Neural Networks* (Guo et al., 2017) – https://arxiv.org/abs/1706.04599 [2] *Deep Double Descent: Where Bigger Models and More Data Hurt* (Nakkiran et al., 2019) – https://arxiv.org/abs/1912.02292

4. Hướng dẫn thực hiện

4.1 Quy trình 6 bước

Mỗi nhóm thực hiện theo 6 bước dưới đây; bước 2 (proposal) là điểm kiểm tra bắt buộc trước khi làm thực nghiệm.

1. **Chọn đề và lập nhóm.** Khuyến khích nhóm 2–3 học viên, cử một trưởng nhóm. Đăng ký 2 nguyện vọng; mỗi chủ đề tối đa 2 nhóm, ưu tiên theo thứ tự đăng ký.
2. **Viết proposal (1–2 trang, nộp cuối tuần 1).** Nêu bài toán, paper chính sẽ tái hiện, dataset, baseline, metric, phân công công việc và tài nguyên tính toán dự kiến (GPU, Colab/Kaggle).
3. **Đọc tài liệu và hệ thống hóa.** Tóm tắt các hướng tiếp cận chính, ưu/nhược điểm, và lý do chọn phương pháp của nhóm. Trình bày phần toán học cốt lõi (hàm mục tiêu, thuật toán tối ưu).
4. **Xây dựng baseline trước.** Chạy một mô hình đơn giản (Linear/Logistic regression, SVM hoặc mô hình chuẩn của bài toán) để có mốc so sánh và kiểm tra pipeline dữ liệu. Nộp báo cáo tiến độ ngắn (kết quả baseline) vào cuối tuần 3.
5. **Tái hiện và thực nghiệm.** Tái hiện kết quả chính của paper, ghi lại chênh lệch so với số liệu công bố và giải thích. Thực hiện ablation study cho ít nhất một thành phần quan trọng.
6. **Cải tiến hoặc ứng dụng (khuyến khích, có điểm thưởng).** Đề xuất một thay đổi về phương pháp, hoặc áp dụng vào một bài toán/dataset thực tế mới, kèm thực nghiệm chứng minh.

4.2 Yêu cầu về thực nghiệm

- Chia dữ liệu train/validation/test rõ ràng; với chuỗi thời gian phải chia theo thời gian, không xáo trộn.
- Chạy ít nhất 3 random seed cho kết quả chính, báo cáo mean ± std.
- Các mô hình được so sánh phải có ngân sách tuning tương đương; nêu rõ không gian siêu tham số đã thử.
- Ghi lại cấu hình phần cứng, thời gian huấn luyện và số tham số mô hình.

4.3 Yêu cầu về mã nguồn

- Python 3.10+, PyTorch hoặc scikit-learn; dùng Git và commit thường xuyên (giảng viên có thể xem lịch sử đóng góp).
- Có `README.md` hướng dẫn cài đặt và chạy lại toàn bộ kết quả, `requirements.txt` hoặc `environment.yml`, file config cho từng thí nghiệm.
- Được dùng code từ repo công khai nhưng phải ghi nguồn và nêu rõ phần nào nhóm tự viết hoặc sửa đổi.

4.4 Sử dụng công cụ AI

> - Được dùng công cụ AI để hỗ trợ viết code và tra cứu, nhưng phải khai báo trong báo cáo (công cụ nào, dùng cho phần nào).
> - Mọi thành viên phải giải thích được mã nguồn và công thức trong báo cáo.

5. Sản phẩm nộp & tiêu chí đánh giá

5.1 Sản phẩm nộp

Mỗi nhóm được đánh giá qua báo cáo đầy đủ và **một trong hai** hình thức trình bày (A: thuyết trình + Q&A trên lớp; B: video thuyết trình). Trưởng nhóm nộp một thư mục qua LMS gồm:

1. **Báo cáo đầy đủ** (PDF, khuyến khích LaTeX, khoảng 8–12 trang chưa kể phụ lục):
   a) Introduction – problem statement, ứng dụng, các cách tiếp cận hiện có kèm ưu/nhược điểm, lý do chọn phương pháp của nhóm.
   b) Methods/Approaches – mô tả tổng quan, kiến trúc/pipeline, các bước chính, công thức cốt lõi.
   c) Experiments – mô tả cài đặt, benchmark dataset, kết quả, ablation, đánh giá và thảo luận.
   d) Improvement or application proposal (khuyến khích, có điểm thưởng).
   e) Conclusion & limitations.
   f) References.
   g) Phụ lục: bảng phân công và mức độ đóng góp (%) của từng thành viên; khai báo sử dụng công cụ AI.
2. **Slide thuyết trình** (phương án A) hoặc **video thuyết trình 10 phút** (phương án B).
3. **Mã nguồn** (hoặc link Git repo) kèm README.

> **Hạn nộp**
> Chậm nhất **2 ngày trước ngày thi cuối kỳ**, nộp qua LMS (trưởng nhóm nộp).

5.2 Rubric đánh giá (thang 10)

Tiêu chí	Trọng số	Biểu hiện mức tốt
Tổng quan & hiểu bài toán	**15%**	Hệ thống hóa được các hướng tiếp cận, so sánh có phản biện
Phương pháp & nền tảng toán học	**20%**	Trình bày đúng, đủ công thức, giải thích được vì sao phương pháp hoạt động
Thực nghiệm & phân tích kết quả	**30%**	Có baseline, nhiều seed, ablation, giải thích kết quả và chênh lệch so với paper
Mã nguồn & khả năng tái lập	**10%**	Chạy lại được theo README, cấu trúc rõ ràng, ghi nguồn đầy đủ
Tiêu chí trình bày (25%) – chỉ chọn MỘT trong hai phương án cho mỗi nhóm		
A. Thuyết trình & Q&A	**25%**	Đúng thời gian (20 phút + 10 phút Q&A), rõ ràng, mọi thành viên trả lời được câu hỏi
B. Video thuyết trình	**25%**	Video 10 phút, mỗi thành viên trình bày một phần; nội dung rõ ràng, có demo hoặc kết quả thực nghiệm minh họa
Cải tiến / ứng dụng mới	**Bonus +1**	Ý tưởng có cơ sở, có thực nghiệm chứng minh
Tổng	**100%**	Cộng điểm thưởng tối đa +1 (thang 10)

> **Lưu ý**
>
> Với mỗi nhóm, giảng viên chỉ chọn **một trong hai** phương án A hoặc B để chấm tiêu chí trình bày (25%), nên tổng điểm luôn là 100%.
>
> Điểm cá nhân có thể điều chỉnh theo bảng đóng góp và phần trả lời Q&A (phương án A) hoặc phần trình bày trong video (phương án B) của từng thành viên.

6. Lịch trình & quy định

6.1 Lộ trình 6–8 tuần

Bài tập lớn kéo dài 6–8 tuần kể từ khi công bố đề; báo cáo phải nộp **chậm nhất 2 ngày trước ngày thi cuối kỳ**. Các mốc trong tuần là đề xuất, giảng viên điều chỉnh theo lịch học kỳ. Lộ trình dưới đây lấy mốc 8 tuần; nếu chỉ có 6 tuần, giai đoạn tái hiện rút còn tuần 4–5 và tuần 6 dành cho hoàn thiện, trình bày.

Tuần 1	Tuần 2–3	Tuần 4–6	Tuần 7–8
Chọn đề, proposal	**Tài liệu, baseline**	**Tái hiện kết quả**	**Hoàn thiện**
• Lập nhóm 2–3 người • Proposal 1–2 trang	• Hệ thống hóa paper • Chạy baseline đơn giản	• Ablation, nhiều seed • Cải tiến / ứng dụng	• Báo cáo + slide/video • Trình bày (A hoặc B)
◆ Duyệt proposal – cuối tuần 1	◆ Báo cáo tiến độ – cuối tuần 3	—	**◆ Nộp báo cáo – chậm nhất 2 ngày trước thi cuối kỳ**

6.2 Hình thức trình bày

- **Phương án A – Thuyết trình:** tuần cuối của bài tập lớn (tuần 6–8 tùy lịch), 20 phút trình bày + 10 phút Q&A mỗi nhóm; thứ tự các nhóm công bố trước 1 tuần.
- **Phương án B – Video thuyết trình:** video 10 phút nộp cùng báo cáo qua LMS, mỗi thành viên trình bày một phần.

6.3 Quy định

- **Nộp trễ:** trừ 10% điểm báo cáo mỗi ngày, tối đa 3 ngày.
- **Liêm chính học thuật:** sao chép báo cáo/mã nguồn của nhóm khác hoặc không ghi nguồn sẽ bị xử lý theo quy định của trường; báo cáo có thể được kiểm tra đạo văn.