VIETNAM NATIONAL UNIVERSITY HO CHI MINH CITY
HO CHI MINH CITY UNIVERSITY OF TECHNOLOGY
FACULTY OF COMPUTER SCIENCE AND ENGINEERING



Học máy và Ứng dụng (CO5175)

Assignment Report

Times Series Forecasting Using Machine Learning

Advisor(s):	Nguyễn An Khương	
	Lê Hồng Trang	
	Trương Vĩnh Lân	
Student(s):	Nguyễn Hồ Quang Khải	2352538
	Đào Duy Đạt	2352223

HO CHI MINH CITY, NOVEMBER 2026

Contents

1 Giới thiệu (Introduction) 1

1.1 Bối cảnh thực tiễn và Phát biểu bài toán (Problem Statement) 1

1.2 Phạm vi ứng dụng trong quản trị chuỗi cung ứng (Application Scope) . . . 2

1.3 Hệ thống hóa các cách dự báo và So sánh phản biện (Forecasting Taxonomy & Critical Review) 3

1.4 Lý do lựa chọn phương pháp và Tuyên bố đóng góp khoa học (Method Selection & Key Contributions) 4

2 Phương pháp và Nền tảng Toán học (Method) 5

2.1 Tổng quan Kiến trúc Hệ thống (Overall System Architecture) 5

2.2 Tái cấu trúc Khung lưới Liên tục & Ràng buộc Chống rò rỉ Thời gian . . . 6

2.2.1 Tái tạo Khung lưới Descartes Liên tục (Continuous Cartesian Grid Reconstruction) 6

2.2.2 Ba Ràng buộc Chống Rò rỉ Dữ liệu Tuyệt đối (Strict No-Lookahead Constraints) 6

2.3 Kỹ thuật Đặc trưng Nhân quả Toàn diện (Causal Feature Engineering) . . 8

2.4 Nền tảng Toán học của Các Mô hình Dự báo (Forecasting Model Zoo) . . 10

2.4.1 Mô hình Chuẩn mực Cơ sở (Baseline Heuristics) 10

2.4.2 Hồi quy Tuyến tính có Điều chuẩn trên Thang Tương đối (Relative-Scale Regularized Linear Regression) 10

2.4.3 Các Kiến trúc Cây Quyết định Tăng cường Gradient (GBDT Model Zoo) 11

3 Thực nghiệm và Đánh giá (Experiments and Evaluation) 12

3.1 Thiết lập Thực nghiệm và Dữ liệu Đối sánh (Benchmark Dataset & Setup) 12

3.2 Hệ thống Đại lượng Đánh giá (Evaluation Metrics) 13

3.3 Cấu hình Thời gian Huấn luyện và Số Tham số (Hardware Profiling & Computational Cost) 14

3.4 Tinh chỉnh Siêu tham số với Ngân sách Đồng nhất (Hyperparameter Tuning under Uniform Budget) 14
3.5 Kiểm định Chéo Chuỗi Thời gian (Rolling Origin Cross-Validation) 15
3.6 Đánh giá Đa Seed và Đối sánh Toàn diện (Baseline vs Linear vs GBDT) . 16
3.7 Nghiên cứu Bóc tách Thành phần (Ablation Study) & Đóng góp Đặc trưng 17
3.8 Đánh giá và Thảo luận (Discussion & Analysis) 18

4 Đề xuất Cải tiến và Mở rộng Nghiệp vụ (Improvement Proposal) 19
4.1 Hướng 1: Chuỗi Ba Giai đoạn Tối ưu hóa Mô hình Học máy ($P1 \rightarrow P2 \rightarrow P3$) 20
4.1.1 Giai đoạn P1: Đồng bộ Hàm mất mát L_1 và Bộ lọc Miền giá trị Không âm Zero-Clipping 20
4.1.2 Giai đoạn P2: Bù đỉnh Cao điểm Ngày lễ & Hòa trộn Mô hình Tập hợp (Duo-Blending) 21
4.1.3 Giai đoạn P3: Thống kê Nhóm Mục tiêu & Tối ưu hóa Siêu tham số Bayesian (Optuna) 23
4.2 Bảng Tổng hợp Tiến trình Cải tiến Xuyên suốt Dự án 24

5 Kết luận (Conclusion) 25
5.1 Các Kết luận Rút ra và Đóng góp Kỹ thuật Cốt lõi (Key Technical Takeaways) 25
5.2 Hạn chế của Nghiên cứu và Hướng Phát triển Tương lai (Limitations and Future Work) 26

Phụ lục (Appendices)

Phụ lục A: Bảng Phân công Công việc và Mức độ Đóng góp Thành viên . . . .

Phụ lục B: Khai báo Sử dụng Công cụ Trí tuệ Nhân tạo (AI Tools Declaration)

Phụ lục C: Bảng Cấu hình Siêu tham số Tối ưu Chi tiết (Hyperparameter Catalog)

List of Figures

List of Tables

3.1 Độ phức tạp tham số và chi phí tính toán của các mô hình GBDT (mean ± std qua 3 seed). 14

3.2 Kết quả tinh chỉnh siêu tham số tự động dưới ngân sách đồng nhất (50 trials / 30 phút). 15

3.3 Kết quả trung bình kiểm định chéo Rolling Origin qua bốn folds (mean ± std). 16

3.4 WMAE theo từng fold của kiểm định chéo Rolling Origin (USD). 16

3.5 Bảng đối sánh hiệu năng tổng thể giữa các trường phái mô hình (mean ± std qua 3 seed). 16

3.6 Ablation Study bóc tách 5 nhóm đặc trưng cộng dồn (mean ± std qua 3 seed). 17

4.1 Đánh giá tác động của bộ lọc Zero-Clipping trên tập kiểm thử ngoài mẫu Holdout Test 2012. 20

4.2 Đối sánh hiệu năng dự báo của Giai đoạn P2 trên tập Validation và Holdout Test (Seed 42). 22

4.3 Đối sánh hiệu năng dự báo của Giai đoạn P3 qua 3 random seeds (mean ± std). 24

4.4 Bảng tổng hợp đối sánh hiệu năng toàn diện qua các giai đoạn phát triển dự án. 24

5.1 Bảng phân công trách nhiệm và tỷ lệ đóng góp của từng thành viên. . . . .

5.2 Khai báo minh bạch về việc sử dụng công cụ AI trong dự án. . . . . .

5.3 Danh mục chi tiết bộ siêu tham số tối ưu của các mô hình học máy. . . . .

Listings

1 Giới thiệu (Introduction)

1.1 Bối cảnh thực tiễn và Phát biểu bài toán (Problem Statement)

Ngày nay, bài toán dự báo doanh số bán hàng của một cửa hàng, công ty hay siêu thị là một trong những bài toán quan trọng trong thị trường buôn bán nói chung và đặc biệt là các ngành bán lẻ quy mô lớn nói riêng, bài toán đó dự báo doanh số bán hàng trong tương lai dựa trên các dữ liệu doanh số được quan sát trong cả hiện tại và cả quá khứ.

Thực tế bài toán đóng vai trò đặc biệt trong lĩnh vực buôn bán khi chỉ với sự sai lệch trong dự báo không chỉ dẫn đến tình trạng đứt gãy nguồn cung tại các điểm bán (out-of-stock), gây tổn thất doanh thu trực tiếp mà còn làm gia tăng chi phí lưu kho và rủi ro khấu hao hàng hóa quá hạn. Do đó, nghiên cứu này tập trung giải quyết bài toán dự báo chuỗi thời gian phân cấp quy mô lớn thông qua bộ dữ liệu chuẩn mực của tập đoàn Walmart [19].

Về mặt toán học, đây là bài toán hồi quy chuỗi thời gian đa biến, đa thực thể và dự báo đa bước tương lai (Hierarchical Multivariate Multi-Step Time-Series Forecasting) [17]. Với hệ thống gồm $S = 45$ siêu thị và tối đa $D = 81$ phòng ban ($M = 3,331$ chuỗi cơ sở $i = (s, d) \in \mathcal{S} \times \mathcal{D}$), tại mốc thời gian T, mục tiêu là ước lượng vector doanh số tương lai $\mathbf{y}_{s,d,T+1:T+H}$ qua $H = 39$ tuần dựa trên lịch sử quan sát $\mathcal{H}_T$ và ma trận ngoại sinh tương lai $\mathbf{X}_{s,d,T+1:T+H}$:

$$\hat{y}_{s,d,T+h} = f_\theta(\mathbf{x}_{s,d,T+h}, \mathcal{H}_T), \quad \forall h \in \{1, 2, \ldots, H\} \tag{1.1}$$

trong đó $\hat{y}_{s,d,T+h} \in \mathbb{R}_{\geq 0}$ là doanh số dự báo, $\mathbf{x}_{s,d,T+h}$ là vector đặc trưng và f_θ là hàm ánh xạ được tham số hóa bởi θ. Mô hình được tối ưu hóa trực tiếp theo thang đo chính thức Weighted Mean Absolute Error (WMAE) [19]:

$$\text{WMAE} = \frac{\sum_{k=1}^{N} w_k |y_k - \hat{y}_k|}{\sum_{k=1}^{N} w_k}, \quad w_k = \begin{cases} 5.0 & \text{nếu tuần } k \text{ là ngày lễ} \\ 1.0 & \text{nếu tuần } k \text{ là tuần thường} \end{cases} \tag{1.2}$$

Hệ thống đối mặt với bốn thách thức kỹ thuật cốt lõi:

1. **Cấu trúc phân cấp và tính dị biệt (Hierarchical Heterogeneity):** Quy mô trải rộng từ 3,331 chuỗi phòng ban, 45 siêu thị đến tổng toàn quốc; đặc tính phân

phối phân hóa mạnh giữa nhóm nhu yếu phẩm ổn định và nhóm hàng mùa vụ bùng nổ đột biến.

2. **Dữ liệu gián đoạn (Intermittent Intervals):** Có 671 chuỗi (20.14%) bị đứt gãy lịch sử do mở muộn hoặc tạm dừng kinh doanh; nếu tính toán trễ trực tiếp trên chỉ số dòng rời rạc sẽ gây lỗi trôi dạt chỉ mục (Index Shift)[12].

3. **Lệch pha lịch ngày lễ di động (Holiday Calendar Shift):** Các kỳ lễ lớn như Thanksgiving dịch chuyển giữa tuần 47 và 48 qua từng năm, khiến các biến trễ chu kỳ năm cố định (lag_{52}) bị mất đồng pha nghiêm trọng.

4. **Hàm tổn thất phạt bất đối xứng (Asymmetric Penalty):** Trọng số phạt $\times 5$ trong WMAE đòi hỏi mô hình phải kiểm soát chuẩn xác các đỉnh doanh số cao điểm thay vì chỉ tối ưu sai số trung bình[19].

1.2 Phạm vi ứng dụng trong quản trị chuỗi cung ứng (Application Scope)

Dự báo chuỗi thời gian chính xác giữ vai trò quan trọng trong hệ thống hoạch định tài nguyên (ERP) và quản trị chuỗi cung ứng (SCM) của doanh nghiệp bán lẻ quy mô lớn như Walmart, trực tiếp định hình ba quyết định kinh doanh chiến lược:

- **Tối ưu tồn kho an toàn (Safety Stock Optimization):** Dự báo chuẩn xác theo từng phòng ban giúp xác định điểm đặt hàng tối ưu (Reorder Point), triệt tiêu nguy cơ đứt gãy nguồn cung tại các tuần cao điểm và giảm chi phí ứ đọng vốn lưu động.

- **Điều phối logistics liên vùng:** Dự báo đón đầu các biến động ngoại sinh vĩ mô như giá nhiên liệu (Fuel Price), chỉ số giá tiêu dùng (CPI) và nhiệt độ giúp chủ động điều chuyển hàng hóa từ tổng kho vùng về các siêu thị vệ tinh.

- **Quản trị chiết khấu thương mại (Markdown Management):** Nắm bắt độ co giãn của cầu theo 5 kênh chiết khấu (MarkDown1–5) giúp tối ưu hóa biên lợi nhuận ròng và giải phóng hàng tồn kho chậm luân chuyển.

Nghiên cứu sử dụng tập dữ liệu giao dịch thực tế gồm 143 tuần huấn luyện (từ 05/02/2010 đến 26/10/2012 với 421,570 quan sát) và 39 tuần kiểm thử tương lai (115,064 quan sát) để kiểm chứng tính thực tiễn của giải pháp.

1.3 Hệ thống hóa các cách dự báo và So sánh phản biện (Forecasting Taxonomy & Critical Review)

Các phương pháp dự báo chuỗi thời gian hiện đại được phân loại thành ba cách tiếp cận chính[11;14]:

1. **Thống kê cổ điển (ARIMA, Exponential Smoothing, Seasonal Naive)**[6;9]: Phương pháp xây dựng các mô hình cục bộ đơn biến (Local Univariate). Dù có nền tảng giải tích chặt chẽ và tính diễn giải cao, cách tiếp cận này bất khả thi trên quy mô lớn khi Auto-ARIMA đòi hỏi độ phức tạp $\mathcal{O}(M \cdot T^3)$. Với $M = 3,331$ chuỗi, mô hình tiêu tốn thời gian tính toán khổng lồ nhưng không thể học tương quan chéo giữa các điểm bán[11]. Ngoài ra, giả định về tính dừng và tính tuyến tính khiến ARIMA hoàn toàn bất lực trước các đỉnh bùng nổ nhu cầu phi tuyến trong mùa mua sắm Thanksgiving.

2. **Học sâu chuỗi thời gian (RNN, LSTM, DeepAR, Transformer)**[3;14;16]: Nhóm mô hình này có thế mạnh tự động trích xuất các phụ thuộc thời gian dài. Tuy nhiên, các khảo sát diện rộng của Zeng et al.[20] và Januschowski et al.[11] chỉ ra rằng: trên các tập dữ liệu dạng bảng kinh doanh có tần suất lấy mẫu thưa (chuỗi hàng tuần ngắn $T = 143$ mốc) và chứa nhiều biến phân loại, các kiến trúc Deep Learning phức tạp thường bị quá khớp (overfitting) nghiêm trọng, rất nhạy cảm với siêu tham số và thường xuyên bị vượt mặt bởi các thuật toán cây quyết định tăng cường gradient.

3. **Học máy dạng bảng toàn cục (Global Tabular ML - GBDT & Regularized Linear)**[7;13;15;18]: Bằng cách chuyển đổi chuỗi thời gian sang bài toán học có giám sát dạng bảng thông qua không gian biến trễ nhân quả, các thuật toán GBDT (LightGBM, XGBoost, CatBoost) thể hiện sự tương thích vượt bậc. GBDT tự động học các tương tác phi tuyến bậc cao giữa thực thể và thời gian, bất biến trước các biến đổi đơn điệu, xử lý linh hoạt giá trị khuyết và cho tốc độ huấn luyện song song trên GPU nhanh gấp hàng chục lần so với mạng nơ-ron sâu[7;8;13].

1.4 Lý do lựa chọn phương pháp và Tuyên bố đóng góp khoa học (Method Selection & Key Contributions)

Xuất phát từ các phân tích trên, nghiên cứu này quyết định lựa chọn cách tiếp cận **Học máy dạng bảng toàn cục (GBDT Zoo & Regularized Linear)** làm mô hình dự báo cơ sở[7;13;15], đồng thời xây dựng ba mô giai đoạn nhằm cải tiến độ hiệu quả các của các mô hình cơ sở nhằm giải quyết triệt để các rào cản kỹ thuật nêu trên.

Nghiên cứu tuyên bố bốn đóng góp kỹ thuật cốt lõi:

1. **Khung lưới Descartes liên tục chống rò rỉ dữ liệu (Continuous Cartesian Grid Framework):** Thiết lập không gian tích Descartes toàn phần $\mathcal{G} = \mathcal{I} \times \mathcal{T}_{\text{all}}$ gồm $M = 3,331$ thực thể và 182 tuần liên tục ($\Delta t = 7$ ngày), tái cấu trúc hoàn hảo 671 chuỗi gián đoạn và gán doanh số tuần khuyết $y_{s,d,t} = 0$, giúp bảo toàn chu kỳ vật lý và triệt tiêu hoàn toàn lỗi Index Shift và Data Leakeage[12].

2. **Hệ thống đặc trưng nhân quả nghiêm ngặt và Bộ ba trễ mùa vụ:** Thiết kế toán tử trễ dịch chuyển nhân quả bắt buộc L^1, quy định mọi đặc trưng trễ hay cửa sổ trượt tại tuần t chỉ được phép khai thác từ tuần $t-1$ trở về trước: $\tilde{y}_{i,t} = L^1(y_{i,t}) = y_{i,t-1}$. Xây dựng bộ ba đặc trưng trễ an toàn $[y_{i,t-51}, y_{i,t-52}, y_{i,t-53}]^\top$ kết hợp biến khoảng cách tuần đến tâm điểm lễ hội $|Week_t - 47|$, giúp mô hình cây hóa giải hoàn toàn hiện tượng lệch pha di động của Lễ Tạ Ơn.

3. **Chuỗi tối ưu hóa thực nghiệm ba giai đoạn ($P1 \to P2 \to P3$):**

   - *Giai đoạn P1:* Đồng bộ hàm mục tiêu chuẩn sai số tuyệt đối L_1 tương thích trực tiếp với bản chất toán học của thước đo WMAE, tích hợp bộ lọc miền giá trị vật lý không âm Zero-Clipping $\hat{y} = \max(0, \hat{y})$, giúp cắt giảm hơn 400% sai số phần trăm tương đối MAPE.
   - *Giai đoạn P2:* Tự động nhận diện 27 ngành hàng bùng nổ nhu cầu ($\mathcal{D}_{\text{surge}}$) để áp dụng bộ nhân bù co giãn Thanksgiving ($\alpha = 1.02$) và thuật toán hòa trộn lồi tối ưu trọng số (Weighted Convex Duo-Blend: 77.4% XGBoost + 22.6% LightGBM)[4], thiết lập kỷ lục sai số kiểm thử WMAE 1,257.03 USD.
   - *Giai đoạn P3:* Tối ưu hóa siêu tham số Bayesian TPE thông qua Optuna[1;5] kết hợp trích xuất 8 đặc trưng thống kê nhóm mục tiêu (Target Group Statistics) được đóng băng nghiêm ngặt theo tập Train, xây dựng mô hình Super Blend đạt hiệu năng tối ưu trên mùa lễ hội Validation (WMAE 1,856.28 USD).

2 Phương pháp và Nền tảng Toán học (Method)

2.1 Tổng quan Kiến trúc Hệ thống (Overall System Architecture)

Hệ thống được thiết kế theo kiến trúc module hóa phân tầng (End-to-End Modular Pipeline Architecture) tuân thủ nguyên tắc dòng dữ liệu một chiều nghiêm ngặt (Unidirectional Data Flow). Mục tiêu kiến trúc là chuyển hóa dữ liệu giao dịch bán lẻ thô, không đồng nhất và bị gián đoạn thành các dự báo có độ chính xác cao, đồng thời triệt tiêu hoàn toàn rủi ro rò rỉ dữ liệu theo trục thời gian (Lookahead Bias / Temporal Data Leakage)[12].

Quy trình vận hành toàn diện của hệ thống được chia thành năm module chức năng kế tiếp nhau:

1. **Module 1: Thu nhận và Chuẩn hóa Dữ liệu thô (Data Ingestion):** Đồng bộ hóa ba bảng dữ liệu quan hệ gồm lịch sử bán hàng ($\mathcal{D}_{\text{sales}}$), thuộc tính thực thể cửa hàng ($\mathcal{D}_{\text{entity}}$), và các chỉ số kinh tế vĩ mô môi trường ($\mathcal{D}_{\text{exog}}$).

2. **Module 2: Phân tích Khám phá & Kiểm định Toàn vẹn Dữ liệu (EDA & Auditing):** Thực hiện kiểm định cấu trúc chuỗi, phát hiện 671 chuỗi bị đứt gãy lịch sử, định lượng hiện tượng trôi dạt lịch Lễ Tạ Ơn (tuần 47 so với tuần 48) và khảo sát tính phân hóa của 81 phòng ban.

3. **Module 3: Tiền xử lý & Kỹ thuật Đặc trưng Chống Rò rỉ (Preprocessing & Leak-Free Feature Engineering):** Tái thiết lập khung lưới thời gian Descartes liên tục, áp dụng toán tử dịch chuyển nhân quả bắt buộc L^1, tạo bộ ba đặc trưng trễ an toàn cho chân trời đa bước, tính toán thống kê cửa sổ trượt và đóng băng thống kê nhóm mục tiêu.

4. **Module 4: Huấn luyện Mô hình Học máy Toàn cục (Global Model Zoo Training):** Huấn luyện đồng thời các mô hình đường cơ sở (Naive, Seasonal Naive, Moving Average), mô hình hồi quy tuyến tính có điều chuẩn trên thang tương đối (Ridge, Lasso) và ba kiến trúc cây quyết định tăng cường gradient toàn cục (LightGBM[13], XGBoost[7], CatBoost[15]).

2.2 Tái cấu trúc Khung lưới Liên tục & Ràng buộc Chống rò rỉ Thời gian

2.2.1 Tái tạo Khung lưới Descartes Liên tục (Continuous Cartesian Grid Reconstruction)

Trong bài toán bán lẻ, 671 chuỗi thời gian không ghi nhận đầy đủ 143 tuần hoạt động. Nếu tính toán các hàm trễ lag_k trực tiếp trên chỉ số dòng dữ liệu thô, khoảng cách thời gian giữa hai dòng kế tiếp sẽ biến động tùy ý, dẫn đến hiện tượng trôi dạt chỉ mục (Index Shift). Để khắc phục triệt để, hệ thống xây dựng không gian lưới Descartes lý thuyết:

$$\mathcal{G} = \mathcal{I} \times \mathcal{T}_{\text{all}} = \{(s, d, t) \mid (s, d) \in \mathcal{I},\, t \in \mathcal{T}_{\text{all}}\} \tag{2.1}$$

trong đó $\mathcal{I} = \mathcal{S} \times \mathcal{D}$ là không gian $M = 3{,}331$ cặp cửa hàng – phòng ban hoạt động, và $\mathcal{T}_{\text{all}} = \{t_1, t_1 + \Delta t, \ldots, T\}$ là trục thời gian chuẩn gồm 182 tuần liên tục với bước nhảy cố định $\Delta t = 7$ ngày.

Khi ánh xạ dữ liệu quan sát thô vào lưới $\mathcal{G}$, các ô lưới khuyết bản ghi được gán nhãn doanh số cơ sở theo ý nghĩa kinh tế học:

$$y_{s,d,t} = 0, \quad \forall (s, d, t) \notin \mathcal{D}_{\text{sales}} \tag{2.2}$$

Đối với các thuộc tính môi trường và kinh tế vĩ mô khuyết thiếu, hệ thống áp dụng cơ chế nội suy nhân quả: truyền thẳng giá trị quan sát gần nhất trong quá khứ xuôi theo trục thời gian (Forward Fill: `ffill`), sau đó bổ sung ngược cho các điểm khởi đầu (Backward Fill: `bfill`) độc lập theo từng cửa hàng:

$$\mathbf{u}_{s,t} = \mathbf{u}_{s,\tau} \quad \text{với} \quad \tau = \max\{\tau' \le t \mid \mathbf{u}_{s,\tau'} \neq \emptyset\} \tag{2.3}$$

Ma trận dữ liệu phẳng liên tục thu được đảm bảo mọi phép toán trễ theo dòng đều phản ánh chính xác khoảng cách tuần thực tế.

2.2.2 Ba Ràng buộc Chống Rò rỉ Dữ liệu Tuyệt đối (Strict No-Lookahead Constraints)

Để đảm bảo tính trung thực khoa học và ngăn chặn hiện tượng quá khớp giả tạo (optimistic evaluation)[12], hệ thống thiết lập ba nguyên lý chống rò rỉ:

1. **Phân tách ranh giới thời gian tuyệt đối (Absolute Time-based Boundary):** Tuyệt đối không sử dụng phép chia mẫu ngẫu nhiên (Random Split) hay K-Fold Cross-Validation tiêu chuẩn. Toàn bộ chuỗi được chia theo các mốc thời gian bất biến:

$$\begin{aligned}\mathcal{T}_{\text{train}} &= \{t \mid t < T_{\text{val}}\} \\ &\quad \text{(05/02/2010 đến 30/09/2011, 255,364 dòng)} \\ \mathcal{T}_{\text{val}} &= \{t \mid T_{\text{val}} \leq t < T_{\text{test}}\} \\ &\quad \text{(Q4/2011, 38,768 dòng, dùng early stopping và tuning)} \\ \mathcal{T}_{\text{test}} &= \{t \mid t \geq T_{\text{test}}\} \\ &\quad \text{(Năm 2012, 127,438 dòng, chỉ dùng báo cáo cuối cùng)}\end{aligned} \tag{2.4}$$

   Mọi thống kê phân phối, chuẩn hóa biến số và tham số trích xuất đặc trưng chỉ được phép tính toán trên $\mathcal{T}_{\text{train}}$ và ánh xạ một chiều (Forward Projection) sang $\mathcal{T}_{\text{val}}$ và $\mathcal{T}_{\text{test}}$.

2. **Cơ chế dịch chuyển trễ nhân quả (Causal Lag Shift Mechanism):** Khi trích xuất vector đặc trưng cho tuần t, giá trị nội sinh $y_{i,t}$ của chính tuần đó tuyệt đối không được phép xuất hiện. Toàn bộ chuỗi mục tiêu bắt buộc phải đi qua toán tử dịch chuyển trễ nhân quả L^1:

$$\tilde{y}_{i,t} = L^1(y_{i,t}) = y_{i,t-1} \tag{2.5}$$

   Mọi toán tử trượt (Rolling Window) hay tỷ số tăng trưởng đều được tính toán trên $\tilde{y}_{i,t}$, đảm bảo mô hình chỉ tiếp cận thông tin đã diễn ra tối thiểu từ tuần $t-1$ trở về trước.

3. **Đặc trưng trễ an toàn cho chân trời đa bước (Multi-step Horizon-Aware Lags):** Trong kịch bản dự báo $H = 39$ tuần liên tiếp không có nhãn quan sát trung gian[17], các độ trễ ngắn hạn $y_{i,t-1}, \ldots, y_{i,t-(H-1)}$ sẽ không tồn tại tại thời điểm suy luận thực tế nếu áp dụng chiến lược dự báo trực tiếp (Direct Forecasting). Hệ thống phân tách tường minh:

$$k \geq H \quad \text{(ví dụ: bộ ba trễ an toàn chu kỳ năm } y_{i,t-51}, y_{i,t-52}, y_{i,t-53}) \tag{2.6}$$

   Các đặc trưng này luôn sẵn sàng trong lịch sử tại thời điểm bắt đầu suy luận, triệt tiêu hoàn toàn rủi ro thiếu hụt dữ liệu hoặc lan truyền sai số đệ quy (Error

Accumulation).

2.3 Kỹ thuật Đặc trưng Nhân quả Toàn diện (Causal Feature Engineering)

Các thuật toán cây quyết định tăng cường gradient (GBDT) vốn không sở hữu cơ chế hồi quy tự nhiên theo trục thời gian và xử lý từng quan sát như các bản ghi dạng bảng độc lập. Do đó, kỹ thuật đặc trưng nhân quả (Causal Feature Engineering) đóng vai trò là cầu nối quyết định với bốn công dụng kỹ thuật then chốt:

- **Chuyển đổi bài toán chuỗi thời gian sang học có giám sát dạng bảng (Tabular Reformulation):** Chuyển hóa toàn bộ chuỗi lịch sử quá khứ thành các vector đặc trưng tĩnh phẳng $\mathbf{x}_{i,t} \in \mathbb{R}^{d_x}$, cho phép các thuật toán GBDT tối ưu hóa các ngưỡng phân nhánh nhị phân (binary split thresholds) trên không gian dữ liệu đa chiều.
- **Bảo đảm nguyên tắc nhân quả và triệt tiêu hoàn toàn rò rỉ dữ liệu (Causality Enforcement & Anti-Leakage):** Áp đặt ràng buộc vật lý một chiều theo thời gian, đảm bảo toàn bộ đặc trưng trễ, thống kê trượt và chỉ số xu hướng tại tuần dự báo t chỉ được tính toán từ các quan sát quá khứ $\tau \leq t-1$, loại trừ hoàn toàn nguy cơ rò rỉ nhãn tương lai (Lookahead Data Leakage) [12].
- **Bóc tách và mã hóa các quy luật biến động nội tại của chuỗi thời gian:** Đồng thời nắm bắt ba thành phần dao động cốt lõi: (i) tính tuần hoàn chu kỳ năm thông qua biến đổi lượng giác, (ii) đà tăng trưởng động học ngắn hạn thông qua thống kê cửa sổ trượt, và (iii) sự lệch pha lịch lễ hội thông qua bộ ba trễ an toàn.
- **Cung cấp ngữ cảnh quy mô tĩnh giúp giảm độ phức tạp của mô hình (Scale Disambiguation):** Cung cấp các phân vị phân phối lịch sử đóng băng của từng phòng ban, giúp mô hình phân tầng chính xác mức doanh thu nền mà không tiêu tốn độ sâu phân nhánh của cây quyết định.

Không gian đầu vào $\mathbf{x}_{i,t} \in \mathbb{R}^{d_x}$ được hiện thực hóa từ 44 đặc trưng chuẩn mực kết hợp 8 đặc trưng mở rộng (Giai đoạn P3) thông qua năm nhóm toán tử toán học:

1. **Toán tử chu kỳ lượng giác (Cyclic Harmonic Trigonometric Transform):** Bảo toàn tính lân cận tuần hoàn của thời gian (tuần 52 nằm liền kề tuần 1 của

năm sau):

$$\phi_{\sin}(t) = \sin\left(\frac{2\pi \cdot \text{Week}_t}{52}\right), \quad \phi_{\cos}(t) = \cos\left(\frac{2\pi \cdot \text{Week}_t}{52}\right) \tag{2.7}$$

Biến đổi tương tự được áp dụng cho chu kỳ tháng ($\text{Month}_t/12$).

2. **Bộ ba trễ mùa vụ an toàn (Safe Seasonal Lag Triplet):** Do Lễ Tạ Ơn dao động giữa tuần 47 và 48, biến trễ đơn lẻ lag_{52} sẽ bị lệch pha trong các năm nhuận lịch lễ. Hệ thống thiết lập bộ ba đặc trưng:

$$\mathbf{h}_{i,t}^{\text{seasonal}} = [y_{i,t-51},\ y_{i,t-52},\ y_{i,t-53}]^\top \tag{2.8}$$

kết hợp biến khoảng cách tuần đến tâm điểm lễ hội $\Delta t_{\text{Thanksgiving}} = |\text{Week}_t - 47|$, giúp thuật toán cây dễ dàng tìm điểm phân nhánh điều chỉnh sai lệch pha.

3. **Toán tử thống kê cửa sổ trượt nhân quả (Causal Rolling Window Statistics):** Tính toán kỳ vọng trượt μ_k và độ biến động phân tán trượt σ_k trên các kích thước cửa sổ $k \in \{4, 8, 52\}$ tuần:

$$\mu_k(i,t) = \frac{1}{k}\sum_{j=1}^{k} y_{i,t-j}, \quad \sigma_k(i,t) = \sqrt{\frac{1}{k-1}\sum_{j=1}^{k}\left(y_{i,t-j} - \mu_k(i,t)\right)^2} \tag{2.9}$$

kèm tỷ số động học tăng trưởng ngắn hạn so với trung hạn:
$r_{\text{growth}}(i,t) = \mu_4(i,t)/(\mu_8(i,t) + \epsilon)$.

4. **Đặc trưng ngoại sinh động & Chương trình khuyến mãi (Exogenous Drivers):** Nhiệt độ, giá nhiên liệu, chỉ số CPI, tỷ lệ thất nghiệp, các biến nhị phân chỉ báo ngày lễ chuyên biệt (`is_super_bowl`, `is_labor_day`, `is_thanksgiving`, `is_christmas`) và 5 kênh chiết khấu thương mại (`MarkDown1-5`), tổng chiết khấu $\sum_{m=1}^{5} \text{MarkDown}_m$ cùng cờ nhị phân `Has_MarkDown`.

5. **Thống kê nhóm mục tiêu lịch sử đóng băng (Frozen Target Group Statistics - P3):** Trích xuất vector thống kê biên cho từng cặp thực thể $i = (s, d)$ duy nhất trên tập huấn luyện $\mathcal{T}_{\text{train}}$:

$$\mathbf{g}_i = \left[\bar{y}_{s,d},\ \tilde{y}_{s,d},\ \sigma_{s,d},\ \max(y_{s,d}),\ \min(y_{s,d}),\ \frac{y_{i,t-52}}{\bar{y}_{s,d} + 1.0},\ \frac{\sum \text{MarkDown}}{\text{Size}_s}\right]^\top \tag{2.10}$$

trong đó $\bar{y}_{s,d}$ là trung bình cộng và $\tilde{y}_{s,d}$ là trung vị lịch sử. Toàn bộ vector $\mathbf{g}_i$ được

đóng băng tham số (Parameter Freezing), cung cấp phân vị nền tảng giúp mô hình cây phân định quy mô doanh thu giữa các quầy hàng mà không tiêu tốn độ sâu phân nhánh.

2.4 Nền tảng Toán học của Các Mô hình Dự báo (Forecasting Model Zoo)

2.4.1 Mô hình Chuẩn mực Cơ sở (Baseline Heuristics)

Các mô hình cơ sở phi tham số (Non-parametric) thiết lập ngưỡng sàn hiệu năng tối thiểu mà các mô hình học máy bắt buộc phải vượt qua:

$$\text{Naive:} \quad \hat{y}_{i,t+h} = y_{i,t-1} \tag{2.11}$$

$$\text{Seasonal Naive:} \quad \hat{y}_{i,t+h} = y_{i,t+h-52} \tag{2.12}$$

$$\text{Moving Average (4W):} \quad \hat{y}_{i,t+h} = \frac{1}{4}\sum_{j=1}^{4} y_{i,t-j} \tag{2.13}$$

2.4.2 Hồi quy Tuyến tính có Điều chuẩn trên Thang Tương đối (Relative-Scale Regularized Linear Regression)

Doanh số giữa các phòng ban Walmart có độ lệch hàng trăm lần (từ vài trăm USD đến hơn 100,000 USD/tuần). Trên thang đo tuyệt đối (USD), mô hình tuyến tính cộng tính sẽ áp cùng một mức tăng tuyệt đối (ví dụ hệ số của `weeks_to_thanksgiving`) cho mọi phòng ban, gây sai số bùng nổ tại các phòng ban quy mô nhỏ.

Để giải quyết, hệ thống đề xuất biến đổi không gian mục tiêu về thang đo tương đối: $y^*_{i,t} = y_{i,t}/s_i$, với $s_i = \max(1.0,\, \bar{y}_{s,d})$ là quy mô doanh số cơ sở của chuỗi. Mô hình hồi quy tuyến tính có điều chuẩn giải bài toán tối ưu lồi[18]:

$$\min_{\mathbf{w},b} \frac{1}{2N}\sum_{k=1}^{N} w_k \cdot s_k \left(y^*_k - (\mathbf{w}^\top \mathbf{x}_k + b)\right)^2 + \alpha \left[\rho\|\mathbf{w}\|_1 + \frac{1-\rho}{2}\|\mathbf{w}\|_2^2\right] \tag{2.14}$$

trong đó $\rho = 1$ tương ứng với hồi quy **Lasso** (L_1), $\rho = 0$ tương ứng với **Ridge** (L_2), $w_k \in \{1, 5\}$ là trọng số ngày lễ của mẫu, và số hạng $w_k \cdot s_k$ đưa hàm mục tiêu bình phương tương đối xấp xỉ lại sai số theo thang USD thực tế.

2.4.3 Các Kiến trúc Cây Quyết định Tăng cường Gradient (GBDT Model Zoo)

Hệ thống triển khai đồng thời ba kiến trúc GBDT tiên tiến nhất [8]:

- **LightGBM [13]:** Sử dụng thuật toán phân nhánh dựa trên Histogram (rời rạc hóa đặc trưng thành $K = 255$ thùng) và cơ chế phát triển cây theo chiều sâu lá (*Leaf-wise Tree Growth*):

$$\Delta\mathcal{L} = \max_{\text{leaf}} \left(\mathcal{L}_{\text{before}} - \mathcal{L}_{\text{after}}\right) \tag{2.15}$$

  Cơ chế này cho phép cây hội tụ sâu hơn và đạt sai số thấp hơn so với phân nhánh theo tầng trên cùng một số lượng nút lá (N_{leaves}). Mô hình được cấu hình với hai hàm mục tiêu: chuẩn L_2 (Baseline) và chuẩn L_1 (`regression_l1` cho P1).

- **XGBoost [7]:** Tối ưu hóa hàm mục tiêu dựa trên xấp xỉ Taylor bậc hai quanh giá trị dự báo của vòng lặp trước $\hat{y}_i^{(t-1)}$:

$$\tilde{\mathcal{L}}^{(t)} \approx \sum_{i=1}^{N} \left[g_i f_t(\mathbf{x}_i) + \frac{1}{2} h_i f_t^2(\mathbf{x}_i) \right] + \gamma T + \frac{1}{2}\lambda \sum_{j=1}^{T} w_j^2 + \alpha \sum_{j=1}^{T} |w_j| \tag{2.16}$$

  với $g_i = \partial_{\hat{y}^{(t-1)}} l(y_i, \hat{y}^{(t-1)})$ là gradient bậc một, và $h_i = \partial^2_{\hat{y}^{(t-1)}} l(y_i, \hat{y}^{(t-1)})$ là hessian bậc hai. XGBoost được cấu hình sử dụng trực tiếp hàm mất mát sai số tuyệt đối L_1 (`reg:absoluteerror`), định hướng dự báo hội tụ trực tiếp về trung vị có điều kiện Median$[y \mid \mathbf{x}]$, hoàn toàn tương thích với bản chất toán học của độ đo WMAE.

- **CatBoost [15]:** Thiết kế dựa trên cấu trúc cây đối xứng đồng dạng (*Oblivious / Symmetric Trees*), trong đó tất cả các nút ở cùng một độ sâu đều sử dụng chung một điều kiện phân nhánh. Kết hợp kỹ thuật *Ordered Boosting* giúp khắc phục hiện tượng dịch chuyển dự báo (Prediction Shift), CatBoost đạt tính ổn định cao và chống quá khớp phân cấp hiệu quả khi tối ưu hóa hàm mất mát căn bậc hai sai số bình phương (RMSE).

3 Thực nghiệm và Đánh giá (Experiments and Evaluation)

3.1 Thiết lập Thực nghiệm và Dữ liệu Đối sánh (Benchmark Dataset & Setup)

Nghiên cứu sử dụng tập dữ liệu chuẩn mực **Walmart Recruiting – Store Sales Forecasting** do Tập đoàn Walmart công bố chính thức trên nền tảng Kaggle[19]. Dữ liệu bao gồm lịch sử giao dịch bán hàng hàng tuần của 45 siêu thị trải rộng trên các vùng địa lý khác nhau của Hoa Kỳ, với tối đa 81 phòng ban/ngành hàng tại mỗi siêu thị. Dữ liệu gốc bao gồm ba tệp tin chính:

- `train.csv` (421,570 dòng): Ghi nhận doanh số tuần (`Weekly_Sales`) từ ngày 05/02/2010 đến ngày 26/10/2012 (143 tuần), kèm định danh `Store`, `Dept`, và cờ boolean `IsHoliday`.
- `features.csv` (8,190 dòng): Chứa các biến ngoại sinh bổ trợ theo từng siêu thị và tuần, bao gồm nhiệt độ trung bình (`Temperature`), giá nhiên liệu (`Fuel_Price`), chỉ số giá tiêu dùng (`CPI`), tỷ lệ thất nghiệp (`Unemployment`) và năm kênh chiết khấu thương mại (`MarkDown1-5`, chỉ bắt đầu được ghi nhận từ tháng 11/2011).
- `stores.csv` (45 dòng): Chứa thuộc tính tĩnh định danh quy mô diện tích mặt sàn (`Size`) và phân loại hình thức siêu thị (`Type` với ba phân lớp A, B, C).

Nhằm triệt tiêu hoàn toàn nguy cơ rò rỉ thông tin từ tương lai và mô phỏng chính xác kịch bản vận hành thực tế[12], toàn bộ dữ liệu được phân chia theo lát cắt thời gian tuần tự (Strict Out-of-Time Boundary Separation):

1. **Tập Huấn luyện (Train Split):** Giai đoạn từ 05/02/2010 đến 30/09/2011 (87 tuần, 255,364 dòng), dùng để ước lượng tham số mô hình và thống kê phân phối.
2. **Tập Thẩm định (Validation Split):** Trọn vẹn Quý 4 năm 2011 (từ 01/10/2011 đến 31/12/2011, 13 tuần, 38,768 dòng). Tập này chứa đầy đủ các đợt bùng nổ nhu cầu mua sắm lớn nhất trong năm (Lễ Tạ Ơn, Black Friday, Giáng Sinh), được sử dụng độc quyền cho cơ chế dừng sớm (Early Stopping) và tinh chỉnh siêu tham số Bayesian.

3. **Tập Kiểm thử Ngoài mẫu (Holdout Test Split):** Toàn bộ giai đoạn năm 2012 (từ 06/01/2012 đến 26/10/2012, 43 tuần, 127,438 dòng). Tập này hoàn toàn vô danh đối với quá trình huấn luyện và chọn lọc tham số, đóng vai trò kiểm tra năng lực tổng quát hóa ngoài mẫu.

3.2 Hệ thống Đại lượng Đánh giá (Evaluation Metrics)

Hiệu năng dự báo được đánh giá toàn diện thông qua hệ thống sáu chỉ số định lượng:

1. **Weighted Mean Absolute Error (WMAE) – Thang đo trọng tâm:**

$$\text{WMAE} = \frac{\sum_{i=1}^{n} w_i |y_i - \hat{y}_i|}{\sum_{i=1}^{n} w_i}, \quad w_i = \begin{cases} 5.0 & \text{nếu tuần } i \text{ là ngày lễ} \\ 1.0 & \text{nếu tuần } i \text{ là bình thường} \end{cases} \tag{3.1}$$

   WMAE là tiêu chí xếp hạng chính thức của bài toán, phản ánh tổn thất chi phí chuỗi cung ứng khi dự báo sai lệch trong các kỳ nghỉ lễ cao điểm.

2. **Mean Absolute Error (MAE) & Root Mean Squared Error (RMSE):**

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^{n} |y_i - \hat{y}_i|, \quad \text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^{n} (y_i - \hat{y}_i)^2} \tag{3.2}$$

   MAE đo lường sai số tuyệt đối trung bình, trong khi RMSE phạt rất nặng các điểm sai số ngoại lai có độ lệch lớn.

3. **Mean Absolute Scaled Error (MASE):** Theo chuẩn mực của Hyndman & Koehler[10], MASE chuẩn hóa sai số dự báo bằng sai số tuyệt đối trong mẫu của mô hình Seasonal Naive chu kỳ $m = 52$ tuần. Đối với dữ liệu bảng gồm $M = 3{,}331$ chuỗi phân cấp, hệ thống tính toán mẫu số gộp chuẩn tắc (*Pooled Scale*):

$$\text{Scale}_{\text{MASE}} = \frac{1}{|\mathcal{K}|} \sum_{(s,d,t) \in \mathcal{K}} |y_{s,d,t} - y_{s,d,t-52}| \tag{3.3}$$

   với $\mathcal{K}$ là tập các cặp thời gian hợp lệ trên lưới tuần liên tục của tập Train. Giá trị $\text{MASE} = \text{MAE}/\text{Scale}_{\text{MASE}} < 1.0$ là minh chứng toán học cho thấy mô hình vượt trội hơn hẳn phương pháp Seasonal Naive cơ sở.

4. **Mean Absolute Percentage Error (MAPE) & Hệ số xác định R^2:**

$$\text{MAPE} = \frac{100\%}{n}\sum_{i=1}^{n}\left|\frac{y_i - \hat{y}_i}{y_i}\right|, \quad R^2 = 1 - \frac{\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}{\sum_{i=1}^{n}(y_i - \bar{y})^2} \tag{3.4}$$

MAPE chỉ mang tính chất tham khảo do dễ bị bùng nổ khi doanh số thực tế tiệm cận 0 USD ($y_i \to 0$).

3.3 Cấu hình Thời gian Huấn luyện và Số Tham số (Hardware Profiling & Computational Cost)

Nhằm đáp ứng yêu cầu minh bạch thực nghiệm, chi phí thời gian huấn luyện (*Fit time*), độ trễ suy luận (*Inference time*) và độ phức tạp tham số mô hình được tổng hợp tại Bảng 3.1.

Table 3.1: Độ phức tạp tham số và chi phí tính toán của các mô hình GBDT (mean ± std qua 3 seed).

Mô hình	Thiết bị	Số tham số (Tổng lá + Node)	Fit time (s)	Inference (s)	Test WMAE (USD)	Test MASE
CatBoost	GPU	120,296 ± 28,153	**18.0 ± 3.8**	**0.25**	1,453.25 ± 22.96	0.729 ± 0.010
XGBoost	GPU	2,154,599 ± 263,964	72.9 ± 9.9	0.62	**1,264.82 ± 5.31**	**0.629 ± 0.002**
LightGBM	CPU	586,225 ± 183,584	154.2 ± 49.4	5.93	1,290.87 ± 4.64	0.645 ± 0.003

Kết quả đo đạc khẳng định: XGBoost trên GPU cho tỷ lệ tối ưu vượt bậc giữa thời gian huấn luyện (72.9 giây) và độ chính xác (1,264.82 USD). CatBoost cho tốc độ suy luận nhanh nhất (0.25 giây cho toàn bộ 127,438 dòng test) nhờ cấu trúc cây đối xứng Oblivious Tree thực thi bằng bitwise.

3.4 Tinh chỉnh Siêu tham số với Ngân sách Đồng nhất (Hyperparameter Tuning under Uniform Budget)

Để đảm bảo tính công bằng tuyệt đối giữa các thuật toán, một ngân sách tinh chỉnh đồng nhất được thiết lập: mỗi mô hình được cấp đúng **50 chu kỳ thử nghiệm (trials)** hoặc tối đa **30 phút** bằng thuật toán tối ưu hóa Bayesian TPE Sampler (*Tree-structured Parzen Estimator*)[5] qua thư viện Optuna[1]. Hàm mục tiêu tối ưu trực tiếp là WMAE trên tập Validation Q4/2011.

Không gian tìm kiếm chung bao gồm: tốc độ học $\eta \in [0.01, 0.1]$, tỷ lệ lấy mẫu hàng subsample $\in [0.6, 1.0]$, tỷ lệ lấy mẫu cột colsample_bytree $\in [0.6, 1.0]$, độ sâu cây

max_depth $\in [4, 10]$ / số nút lá num_leaves $\in [15, 127]$, và hệ số chính quy hóa reg_alpha, reg_lambda $\in [10^{-3}, 10.0]$. Kết quả thu được tại Bảng 3.2.

Table 3.2: Kết quả tinh chỉnh siêu tham số tự động dưới ngân sách đồng nhất (50 trials / 30 phút).

Mô hình	Best Val WMAE (USD)	Số trial	Thời gian	Bộ siêu tham số tối ưu tìm được
CatBoost	2,636.53	50	17.5 phút	lr=0.0513 depth=8 subsample=0.643 colsample=0.688
LightGBM	2,108.84	34	30.7 phút	lr=0.0572 num_leaves=90 subsample=0.795 reg_alpha=0.034
XGBoost	**1,723.67**	39	30.6 phút	lr=0.0237 max_depth=10 subsample=0.893 colsample=0.839

3.5 Kiểm định Chéo Chuỗi Thời gian (Rolling Origin Cross-Validation)

Kiểm định chéo k-fold thông thường làm xáo trộn trục thời gian, vi phạm tính nhân quả. Nghiên cứu triển khai phương pháp **Rolling Origin Cross-Validation** (cửa sổ mở rộng – Expanding Window) gồm 4 nấc thử nghiệm tuần tự, mỗi fold dự báo đúng 13 tuần (1 quý) ở chế độ an toàn chân trời (`horizon_safe`: che hoàn toàn doanh số tương lai và tái tính toán ma trận đặc trưng trễ):

- **Fold 1:** Huấn luyện đến 30/04/2011 $\longrightarrow$ Kiểm định: Tháng 05/2011 đến 07/2011 (13 tuần).
- **Fold 2:** Huấn luyện đến 31/07/2011 $\longrightarrow$ Kiểm định: Tháng 08/2011 đến 10/2011 (13 tuần).
- **Fold 3 (Q4 Mùa Lễ hội):** Huấn luyện đến 31/10/2011 $\longrightarrow$ Kiểm định: Tháng 11/2011 đến 01/2012 (13 tuần).
- **Fold 4:** Huấn luyện đến 31/01/2012 $\longrightarrow$ Kiểm định: Tháng 02/2012 đến 04/2012 (13 tuần).

Table 3.3: Kết quả trung bình kiểm định chéo Rolling Origin qua bốn folds (mean ± std).

Mô hình	MAE (USD)	RMSE (USD)	MASE	WMAE (USD)
CatBoost	2,204.03 ± 443.52	4,678.50 ± 1,309.21	1.072 ± 0.235	2,273.91 ± 526.09
XGBoost	1,882.54 ± 279.81	4,795.91 ± 1,929.02	**0.915 ± 0.148**	1,982.46 ± 428.65
LightGBM	**1,882.81 ± 292.84**	**4,680.80 ± 1,836.13**	0.916 ± 0.164	**1,963.67 ± 411.77**

Table 3.4: WMAE theo từng fold của kiểm định chéo Rolling Origin (USD).

Mô hình	Fold 1	Fold 2	Fold 3	Fold 4
CatBoost	2,352	1,850	**2,987**	1,905
XGBoost	2,025	1,633	**2,572**	1,700
LightGBM	1,952	1,588	**2,540**	1,775

Nhận định cốt lõi từ kiểm định chéo:Bảng 3.4 cho thấy tại **Fold 3 (Quý 4)**, sai số WMAE của tất cả các mô hình đều tăng vọt hơn 50% so với các quý thông thường (đạt từ 2,540 đến 2,987 USD). Điều này khẳng định tính dị biệt và thách thức cực độ của các đợt cao điểm mua sắm Lễ Tạ Ơn và Giáng Sinh, đòi hỏi các cơ chế can thiệp chuyên biệt như bộ nhân co giãn mùa vụ.

3.6 Đánh giá Đa Seed và Đối sánh Toàn diện (Baseline vs Linear vs GBDT)

Nhằm kiểm chứng tính ổn định của các thuật toán và loại bỏ yếu tố ngẫu nhiên, toàn bộ các mô hình được huấn luyện lặp lại qua 3 random seeds độc lập ($\{42, 123, 2024\}$). Bảng 3.5 tổng hợp toàn bộ kết quả đối sánh giữa các trường phái mô hình trên cả tập Validation Q4/2011 và tập Holdout Test 2012.

Table 3.5: Bảng đối sánh hiệu năng tổng thể giữa các trường phái mô hình (mean ± std qua 3 seed).

Trường phái	Mô hình thực nghiệm	Val WMAE (USD)	Test WMAE (USD)	Test MAE (USD)	Test RMSE (USD)	Test MASE	Test R^2
Baseline	Naive (y_{t-1})	2,863.39 ± 0.00	2,863.39 ± 0.00	2,203.65 ± 0.00	7,611.64 ± 0.00	1.121 ± 0.000	0.8877
Baseline	Seasonal Naive (y_{t-52})	2,294.98 ± 0.00	1,775.43 ± 0.00	1,768.31 ± 0.00	3,784.16 ± 0.00	0.899 ± 0.000	0.9707
Baseline	Moving Average 4W	4,424.14 ± 0.00	2,006.54 ± 0.00	1,941.02 ± 0.00	4,847.24 ± 0.00	0.987 ± 0.000	0.9520
Linear	Ridge ($\alpha = 0.1$)	3,998.28 ± 0.00	1,638.50 ± 0.00	1,641.54 ± 0.00	3,589.86 ± 0.00	0.834 ± 0.000	0.9737
Linear	Lasso ($\alpha = 0.001$, 26 đặc trưng)	3,888.46 ± 0.00	1,564.00 ± 0.00	1,537.42 ± 0.00	3,445.95 ± 0.00	0.781 ± 0.000	0.9757
GBDT	CatBoost (Tuned GPU)	2,696.62 ± 52.79	1,453.25 ± 22.96	1,434.26 ± 19.64	3,055.42 ± 34.94	0.729 ± 0.010	0.9817
GBDT	LightGBM (Tuned CPU)	2,121.34 ± 87.49	1,290.87 ± 4.64	1,269.50 ± 5.13	2,818.54 ± 11.59	0.645 ± 0.003	**0.9850**
GBDT	**XGBoost (Tuned GPU)**	**1,785.02 ± 57.25**	**1,264.82 ± 5.31**	**1,237.98 ± 4.76**	**2,751.49 ± 20.51**	**0.629 ± 0.002**	0.9845

Phân tích kết quả thực nghiệm:

1. **Khoảng cách giữa Baseline và Machine Learning:** Toàn bộ các mô hình học máy đều vượt trội hơn các mô hình chuẩn mực thống kê. XGBoost cắt giảm WMAE Test từ 1,775.43 USD (Seasonal Naive) xuống 1,264.82 USD (giảm 28.8%), đưa chỉ số MASE từ 0.899 xuống 0.629.

2. **Vai trò của Mô hình Tuyến tính có điều chuẩn:** Khi được huấn luyện trên thang đo tương đối y/s, Lasso đạt WMAE Test 1,564.00 USD (tốt hơn Seasonal Naive 11.9%). Tuy nhiên, tại mùa lễ Q4, Lasso thất bại hoàn toàn (Val WMAE 3,888.46 USD) do cấu trúc cộng tính không thể mô hình hóa tương tác phi tuyến giữa sự kiện ngày lễ và từng ngành hàng đặc thù.

3. **Ưu thế tuyệt đối của hàm mất mát L_1 trên XGBoost:** XGBoost đạt kết quả tốt nhất ở cả Validation (1,785.02 USD) và Test (1,264.82 USD) nhờ hàm mục tiêu `reg:absoluteerror` hướng mô hình hội tụ trực tiếp về trung vị có điều kiện, hoàn toàn trùng khớp với bản chất toán học của độ đo WMAE.

3.7 Nghiên cứu Bóc tách Thành phần (Ablation Study) & Đóng góp Đặc trưng

Để định lượng đóng góp thực sự của từng nhóm đặc trưng, nghiên cứu tiến hành Ablation Study cộng dồn trên kiến trúc XGBoost qua 3 seed (Bảng 3.6).

Table 3.6: Ablation Study bóc tách 5 nhóm đặc trưng cộng dồn (mean ± std qua 3 seed).

Cấu hình	Nhóm đặc trưng bổ sung	Số đặc trưng	Val WMAE (USD)	Δ Val WMAE	Test WMAE (USD)	Test MASE
C1	Lags thuần túy	12	$3{,}162.87 \pm 42.88$	–	$1{,}359.98 \pm 6.20$	0.676 ± 0.002
C2	+ Thống kê trượt (Rolling)	18	$3{,}060.47 \pm 32.80$	-102.39	$1{,}351.88 \pm 1.94$	0.671 ± 0.001
C3	**+ Lịch & Cờ ngày lễ**	33	$\mathbf{1{,}856.31 \pm 43.36}$	$\mathbf{-1{,}204.16}$	$\mathbf{1{,}267.93 \pm 2.95}$	$\mathbf{0.630 \pm 0.001}$
C4	+ Biến ngoại sinh (Exogenous)	44	$1{,}900.69 \pm 48.32$	$+44.37$	$1{,}281.69 \pm 3.66$	0.638 ± 0.002
C5	+ Target Group Stats (P3)	52	$1{,}838.52 \pm 2.46$	-62.17	$1{,}311.60 \pm 3.06$	0.653 ± 0.001

Phân tích Đóng góp Đặc trưng (Feature Importance Insights):

- **Đột phá từ nhóm Lịch & Lễ hội (C3):** Bổ sung biến lượng giác và cờ lễ hội giúp giảm ngoạn mục $-1{,}204.16$ **USD** (-39.3%) Val WMAE, đóng vai trò quyết định giúp mô hình định vị chính xác các đỉnh mua sắm Quý 4. Ngược lại, nhóm biến vĩ mô (C4) biến động chậm và trễ pha nên làm tăng nhẹ $+44.37$ USD sai số.

- **Phân rã độ lợi phân nhánh (Total Gain):** Phân tích độ lợi cây tại cấu hình đầy đủ C5 chỉ ra rằng quán tính doanh số tuần liền kề (`sales_lag_1`) chi phối lớn

nhất với **33.03**% Gain, kế tiếp là mã ngành hàng (`Dept`, 12.18%) và siêu thị (`Store`, 9.96%). Đặc biệt, đặc trưng mới bổ sung ở giai đoạn P3 là `store_dept_median` lọt thẳng vào Top-5 biến quan trọng nhất (8.32% Gain), minh chứng rõ nét cho giá trị của ngữ cảnh phân phối quy mô tĩnh. (Bảng phân rã chi tiết Top-10 đặc trưng được trình bày tại Phụ lục).

3.8 Đánh giá và Thảo luận (Discussion & Analysis)

- **Nghịch lý bùng nổ MAPE (MAPE Explosion):** Mặc dù vượt trội về WMAE, các mô hình GBDT ghi nhận MAPE rất cao (500% đến $>$ 1,000%). Bản chất xuất phát từ mẫu số y_i tiệm cận 0 tại các quầy đổi trả hàng hoặc trái mùa (ví dụ $y_i = 1.5$ USD, dự báo $\hat{y}_i = 50.0$ USD tạo ra APE $= |1.5 - 50|/1.5 \approx 3{,}233\%$). Một số ít quan sát tiệm cận 0 này làm méo mó trung bình cộng MAPE, chứng minh MAPE hoàn toàn không phù hợp làm độ đo xếp hạng; WMAE, MAE và MASE mới là thước đo phản ánh trung thực năng lực mô hình.
- **Chênh lệch phân phối giữa Validation Q4 và Holdout Test 2012:** Sai số WMAE trên Validation Q4 (1,785.02 USD) cao hơn đáng kể so với Holdout Test (1,264.82 USD) không phải do quá khớp (overfitting), mà phản ánh sự khác biệt căn bản về phân phối: Validation tập trung trọn vẹn 13 tuần cao điểm lễ hội với phương sai bùng nổ và trọng số phạt $\times 5$ chiếm tỷ trọng lớn; trong khi Test trải dài 43 tuần với đa số là các tuần kinh doanh ổn định. Độ lệch chuẩn đa seed rất nhỏ (± 5.31 USD) trên Test khẳng định năng lực tổng quát hóa vững chắc của mô hình.

4 Đề xuất Cải tiến và Mở rộng Nghiệp vụ (Improvement Proposal)

Từ các kết quả phân tích chẩn đoán ở Phần 3, mô hình học máy cơ sở bộc lộ ba điểm nghẽn kỹ thuật điển hình trong bài toán chuỗi thời gian bán lẻ:

1. **Lệch pha hàm mục tiêu và bùng nổ sai số tương đối (Objective-Metric Mismatch & MAPE Explosion):** Mô hình cây toàn phương (L_2) hội tụ về kỳ vọng có điều kiện $\mathbb{E}[y \mid \mathbf{x}]$ thay vì trung vị theo chuẩn L_1 của thang đo WMAE, đồng thời dự báo ra các giá trị âm mang tính phi lý vật lý ($\hat{y} < 0$), khiến sai số phần trăm MAPE bùng nổ lên tới hơn 800% trên các phòng ban quy mô nhỏ.
2. **Hạn chế nén biên độ tại các đỉnh đột biến lễ hội (Under-prediction at Holiday Peaks):** Bản chất trung bình hóa mẫu cục bộ tại các nút lá của thuật toán GBDT khiến mô hình có xu hướng dự báo nén thấp hơn thực tế tại các tuần cao điểm mua sắm Lễ Tạ Ơn (tuần 47) và Giáng Sinh (tuần 51), trong khi các mô hình đơn lẻ chưa phát huy được tính bổ trợ tương hỗ.
3. **Thiếu hụt ngữ cảnh phân phối quy mô chéo và chưa tối ưu siêu tham số (Lack of Scale Context & Sub-optimal Hyperparameters):** Các biến trễ và trượt động học ngắn hạn không cung cấp đủ ngữ cảnh quy mô dài hạn giữa các thực thể Cửa hàng × Phòng ban khác nhau (quầy lớn doanh số hàng chục ngàn USD đối lập với quầy nhỏ vài trăm USD), đồng thời không gian siêu tham số mặc định chưa được khai phá triệt để.

Nhằm giải quyết triệt để ba điểm nghẽn kỹ thuật trên, nghiên cứu thiết kế và triển khai **Lộ trình Cải tiến Ba Giai đoạn Chuyên sâu (P1 → P2 → P3)**:

- **Giai đoạn P1:** Đồng bộ Hàm mất mát L_1 (`regression_l1`) và tích hợp Bộ lọc Miền giá trị Vật lý Zero-Clipping.
- **Giai đoạn P2:** Tinh chỉnh Bù biên độ Lễ hội (Holiday Surge Multiplier) và Hòa trộn Lồi Tối ưu Hai Mô hình (Weighted Duo-Blend).
- **Giai đoạn P3:** Bổ sung 8 đặc trưng Thống kê Nhóm mục tiêu (Target Group Statistics), Tinh chỉnh Siêu tham số Bayesian (Optuna) và Siêu Mô hình Tập hợp (Super-Blend).

4.1 Hướng 1: Chuỗi Ba Giai đoạn Tối ưu hóa Mô hình Học máy ($P1 \rightarrow P2 \rightarrow P3$)

4.1.1 Giai đoạn P1: Đồng bộ Hàm mất mát L_1 và Bộ lọc Miền giá trị Không âm Zero-Clipping

Cơ sở lý thuyết & Động lực thực hiện: Hàm mất mát chuẩn L_2 cực tiểu hóa sai số bình phương trung bình (MSE), định hướng dự báo tiệm cận kỳ vọng có điều kiện $\mathbb{E}[y \mid \mathbf{x}]$. Trong khi đó, thang đo đánh giá chính thức WMAE dựa trên chuẩn sai số tuyệt đối L_1, vốn đòi hỏi dự báo phải hội tụ về trung vị có điều kiện Median$[y \mid \mathbf{x}]$. Sự lệch pha này khiến mô hình L_2 bị kéo lệch bởi các ngoại lai lớn. Đồng thời, các phòng ban có doanh số thực tế rất nhỏ ($y \to 0$) khi nhận dự báo âm ($\hat{y} = -15$ USD do nhiễu phân phối phần dư) sẽ khiến phép chia APE $= |(y - \hat{y})/y|$ bùng nổ lên hàng ngàn phần trăm.

Giải pháp kỹ thuật triển khai:

1. Chuyển đổi hàm mục tiêu của LightGBM từ L_2 sang chuẩn sai số tuyệt đối:

$$\mathcal{L}_{L_1}(y, \hat{y}) = |y - \hat{y}| \quad \Longrightarrow \quad \texttt{params['objective'] = 'regression_l1'} \tag{4.1}$$

2. Tích hợp bộ lọc toán tử cắt ngưỡng dưới dạng phép chiếu lồi lên không gian số thực không âm $\mathbb{R}_{\geq 0}$:

$$\hat{y}_i^{\text{clipped}} = \max\left(0,\, \hat{y}_i^{\text{raw}}\right) \tag{4.2}$$

Kết quả thực nghiệm đối sánh Giai đoạn P1: Bảng 4.1 tổng hợp tác động của phép lọc Zero-Clipping trên cả ba kiến trúc mô hình tại tập kiểm thử ngoài mẫu Holdout Test 2012.

Table 4.1: Đánh giá tác động của bộ lọc Zero-Clipping trên tập kiểm thử ngoài mẫu Holdout Test 2012.

Kiến trúc mô hình	WMAE Thô (USD)	WMAE Clipped	Mức giảm WMAE ↓	MAPE Thô (%)	MAPE Clipped	Mức giảm MAPE ↓
LightGBM (Base L_2)	1,304.14	1,298.32	**−5.82** USD	904.52%	625.81%	**−278.71**%
LightGBM (P1 L_1)	1,316.14	1,315.66	−0.48 USD	521.83%	486.46%	**−35.37**%
XGBoost (Base L_1)	1,280.24	1,279.43	−0.81 USD	1,112.70%	1,063.66%	−49.04%
CatBoost (Base RMSE)	1,440.43	1,435.39	**−5.04** USD	1,228.04%	741.52%	**−486.52**%

Nhận định kết quả P1:

- Việc kết hợp hàm mất mát L_1 và Zero-Clipping giúp cắt giảm trực tiếp từ 5.04 đến 5.82 USD sai số WMAE trên các mô hình tối ưu theo chuẩn bình phương (LightGBM, CatBoost) mà không phát sinh thêm bất kỳ chi phí tính toán nào.
- Trên LightGBM P1, sai số tương đối MAPE giảm mạnh từ 904.52% xuống 486.46% trên Test (và giảm từ 211.31% xuống 84.96% trên tập Validation), triệt tiêu hoàn toàn hiện tượng dự báo âm vô lý trong vận hành chuỗi cung ứng.

4.1.2 Giai đoạn P2: Bù đỉnh Cao điểm Ngày lễ & Hòa trộn Mô hình Tập hợp (Duo-Blending)

Cơ sở lý thuyết & Động lực thực hiện:

- *Hạn chế nén biên độ của cây quyết định:* Cây hồi quy phân vùng không gian đặc trưng thành các siêu khối trực giao và gán giá trị dự báo bằng trung bình cục bộ tại các nút lá. Cơ chế này luôn có xu hướng nén biên độ và dự báo thấp hơn thực tế tại các điểm đột biến nhu cầu cực hạn như tuần Lễ Tạ Ơn (Thanksgiving / Black Friday).
- *Tính phân hóa phi đồng nhất giữa các ngành hàng:* Phân tích EDA chỉ ra rằng đợt bùng nổ doanh số không diễn ra đồng đều trên toàn bộ siêu thị mà tập trung cục bộ vào một nhóm ngành hàng nhạy cảm (đồ chơi, quà tặng, điện máy gia dụng với mức tăng từ 1.4× đến hơn 3.8×). Việc áp dụng hệ số nhân toàn cục sẽ làm méo mó các ngành hàng thiết yếu ổn định.
- *Nguyên lý giảm phương sai tập hợp (Ensemble Variance Reduction)*[4]*:* XGBoost tối ưu hóa cục bộ rất tốt theo chuẩn sai số tuyệt đối L_1, trong khi LightGBM duy trì tính mượt phân tán nhờ hàm mất mát L_2. Việc kết hợp hai mô hình bổ trợ này theo một tổ hợp lồi tối ưu sẽ làm giảm phương sai sai số dự báo tổng thể.

Giải pháp kỹ thuật triển khai:

1. **Nhận diện tự động cụm ngành hàng bùng nổ (Surge Departments):** Hệ thống tự động phân loại 27 ngành hàng có tốc độ tăng trưởng doanh số tại tuần cao điểm thứ 47 so với mức trung bình năm vượt ngưỡng quy định ($\geq 1.35\times$):

$$\mathcal{D}_{\text{surge}} = \{5, 6, 7, 8, 9, 10, 11, 12, 14, 17, 18, 20, 21, 22, \\ 23, 24, 25, 27, 31, 32, 34, 45, 55, 72, 87, 92, 95\} \tag{4.3}$$

2. **Bộ nhân co giãn đỉnh lễ hội (Thanksgiving Multiplier):** Áp dụng công thức hiệu chỉnh có chọn lọc tại tuần biến cố 47:

$$\hat{y}_{i,t}^{\text{adj}} = \begin{cases} \alpha \cdot \hat{y}_{i,t}^{\text{clip}} & \text{với } d \in \mathcal{D}_{\text{surge}} \text{ và } t = 47 \quad (\alpha = 1.02) \\ \hat{y}_{i,t}^{\text{clip}} & \text{trường hợp còn lại} \end{cases} \tag{4.4}$$

3. **Hòa trộn mô hình lồi tối ưu (Weighted Convex Duo-Blending):** Thiết lập bài toán tối ưu hóa lồi tìm tỷ lệ trọng số hòa trộn tối ưu nhằm cực tiểu hóa trực tiếp hàm mục tiêu WMAE trên tập Validation Q4/2011:

$$\hat{y}_{i,t}^{\text{Blend}} = w_1^* \cdot \hat{y}_{i,t}^{(\text{XGBoost})} + w_2^* \cdot \hat{y}_{i,t}^{(\text{LightGBM})} \quad \text{s.t.} \quad w_1^* + w_2^* = 1,\ w_1^*, w_2^* \geq 0 \tag{4.5}$$

Thuật toán tối ưu hóa xác định nghiệm hội tụ tối ưu: $\mathbf{w}^* = [0.774,\ 0.226]^\top$ (tương ứng 77.4% XGBoost +22.6% LightGBM).

Kết quả thực nghiệm đối sánh Giai đoạn P2: Bảng 4.2 đối sánh chi tiết hiệu năng của Giai đoạn P2 so với các mô hình đơn lẻ trên cả hai tập dữ liệu.

Table 4.2: Đối sánh hiệu năng dự báo của Giai đoạn P2 trên tập Validation và Holdout Test (Seed 42).

Mô hình / Cấu hình thực nghiệm	Val WMAE (USD)	Val RMSE (USD)	Test WMAE (USD)	Test RMSE (USD)	Test R^2
XGBoost (ML Baseline)	1,924.47	4,570.76	1,279.43	2,754.55	0.9845
LightGBM (ML Baseline)	2,253.53	4,836.68	1,295.66	2,717.29	0.9849
XGBoost + Holiday Multiplier	1,922.15	4,527.44	1,279.43	2,754.55	0.9845
P2: Weighted Duo Blend (77.4% + 22.6%)	1,886.92	4,407.28	1,257.03	2,687.90	0.9852
P2: Duo Blend + Holiday Multiplier	**1,885.49**	**4,364.00**	**1,257.03**	**2,687.90**	**0.9852**

Nhận định kết quả P2:

- **Thiết lập kỷ lục Test WMAE thấp nhất toàn dự án:** Phương pháp hòa trộn Duo-Blend đưa WMAE kiểm thử giảm sâu xuống mốc kỷ lục 1,257.03 **USD** (cắt giảm 22.40 USD so với mô hình đơn tốt nhất). Khi đánh giá đa seed ($\{42, 123, 2024\}$), P2 duy trì hiệu năng vững chắc: $1{,}264.39 \pm 3.04$ **USD**, đạt hệ số giải thích phương sai $R^2 = 0.9852$.
- **Kiểm soát xuất sắc mùa cao điểm Lễ Tạ Ơn:** Trên tập Validation Q4, sai số WMAE giảm mạnh từ 1,924.47 USD xuống 1,885.49 USD (cắt giảm tới 38.98 USD), đồng thời RMSE giảm từ 4,570.76 xuống 4,364.00 USD.

4.1.3 Giai đoạn P3: Thống kê Nhóm Mục tiêu & Tối ưu hóa Siêu tham số Bayesian (Optuna)

Cơ sở lý thuyết & Động lực thực hiện: Hệ thống sử dụng một mô hình toàn cục duy nhất để học đồng thời 3,331 chuỗi thời gian dị biệt. Cấu trúc cây quyết định phải tiêu tốn nhiều tầng phân nhánh độ sâu chỉ để phân tách thang đo doanh thu cơ sở giữa các thực thể có quy mô chênh lệch hàng chục lần. Do đó, việc cung cấp trực tiếp vector phân phối lịch sử biên (Priors) cho từng cặp (s, d) sẽ giúp mô hình nắm bắt tức thì phân vị hoạt động tĩnh. Đồng thời, không gian siêu tham số đa biến cần được tối ưu hóa tự động bằng thuật toán Bayesian nhằm thiết lập trạng thái cân bằng giữa tốc độ học và độ sâu cây.

Giải pháp kỹ thuật triển khai:

1. **Trích xuất 8 đặc trưng thống kê nhóm mục tiêu (Target Group Statistics):**
   - `store_dept_mean`, `store_dept_median`, `store_dept_std`: Trung bình, trung vị và độ lệch chuẩn lịch sử đóng băng theo tập Train.
   - `store_dept_max`, `store_dept_min`: Cực trị doanh số lịch sử.
   - `ratio_lag52_to_mean`: Tỷ số cùng kỳ năm trước so với trung bình lịch sử $\frac{y_{t-52}}{\bar{y}_{s,d}+1.0}$.
   - `markdown_to_sales_density`: Mật độ ngân sách chiết khấu trên quy mô diện tích mặt sàn siêu thị.
   - `is_holiday_surge_dept`: Cờ nhị phân phân loại phòng ban bùng nổ ngày lễ.
2. **Tối ưu hóa siêu tham số Bayesian với Optuna (TPESampler)** [1;5]**:** Khởi tạo không gian tìm kiếm Bayesian qua 15 chu kỳ thử nghiệm (trials) tối ưu trực tiếp hàm mất mát WMAE Validation. Bộ tham số tối ưu thu được: learning_rate = 0.0613, num_leaves = 60, min_child_samples = 25, subsample = 0.855, colsample_bytree = 0.782, reg_alpha = 0.0028, reg_lambda = 0.0679.
3. **Xây dựng mô hình Super Blend toàn diện:** Hòa trộn dự báo giữa XGBoost cơ sở với mô hình LightGBM P3 tối ưu kết hợp bộ nhân Thanksgiving Multiplier.

Kết quả thực nghiệm đối sánh Giai đoạn P3: Bảng 4.3 tổng hợp hiệu năng đối sánh chi tiết của toàn bộ các cấu hình trong Giai đoạn P3 qua 3 random seeds.

Table 4.3: Đối sánh hiệu năng dự báo của Giai đoạn P3 qua 3 random seeds (mean ± std).

Mô hình / Cấu hình thực nghiệm	Val WMAE (USD)	Val RMSE (USD)	Test WMAE (USD)	Test MASE	Test R^2
ML Baseline: LightGBM (L_2)	$2{,}295.66 \pm 31.38$	$4{,}948.02 \pm 74.16$	$1{,}300.67 \pm 10.33$	0.650 ± 0.005	0.9850
ML Baseline: XGBoost (L_1)	$1{,}906.48 \pm 54.88$	$4{,}588.58 \pm 138.61$	$1{,}280.85 \pm 2.48$	0.638 ± 0.002	0.9843
Giai đoạn P1: LightGBM (L_1 + Zero-Clip)	$2{,}226.32 \pm 10.27$	$5{,}688.75 \pm 184.06$	$1{,}304.64 \pm 11.30$	0.652 ± 0.005	0.9833
Giai đoạn P2: Weighted Duo Blend	$1{,}887.31 \pm 51.29$	$4{,}433.23 \pm 101.99$	$\mathbf{1{,}264.39 \pm 3.04}$	$\mathbf{0.630 \pm 0.002}$	**0.9849**
P3: LightGBM đơn (GroupStats + Optuna)	$2{,}095.66 \pm 43.55$	$5{,}090.22 \pm 98.06$	$1{,}327.43 \pm 4.81$	0.663 ± 0.003	0.9832
P3: Super Blend + Multiplier [TỐI ƯU VAL]	$\mathbf{1{,}856.28 \pm 38.24}$	$\mathbf{4{,}542.16 \pm 102.49}$	$1{,}268.98 \pm 0.61$	0.632 ± 0.001	0.9845

Nhận định kết quả P3:

- **Bước nhảy vọt của mô hình đơn lẻ:** Việc bổ sung vector thống kê nhóm và siêu tham số Optuna giúp mô hình đơn lẻ LightGBM P3 giảm sai số Val WMAE từ 2,295.66 USD xuống 2,095.66 USD (cắt giảm tới 200.00 **USD**, tương đương cải thiện -8.7%).
- **Kỷ lục tối ưu tuyệt đối trên mùa lễ hội Validation:** Cấu hình Super Blend kết hợp Thanksgiving Multiplier thiết lập kỷ lục Val WMAE thấp nhất toàn bộ dự án: $1{,}856.28 \pm 38.24$ **USD**, khẳng định năng lực kiểm soát vượt trội trong điều kiện dữ liệu chịu trọng số phạt bất đối xứng $\times 5$.

4.2 Bảng Tổng hợp Tiến trình Cải tiến Xuyên suốt Dự án

Bảng 4.4 hệ thống hóa toàn bộ hành trình nghiên cứu và tối ưu hóa giải pháp, phản ánh sự biến chuyển định lượng từ các mô hình kinh điển đến giải pháp học máy tập hợp phân cấp tối ưu.

Table 4.4: Bảng tổng hợp đối sánh hiệu năng toàn diện qua các giai đoạn phát triển dự án.

Giai đoạn	Phương pháp thực nghiệm	Test WMAE (USD)	Giảm vs Baseline (%)	Val WMAE (USD)	Test MAPE (%)	Tính nhất quán
Benchmark Gốc	Moving Average (4W)	2,006.54	0.00% (Mốc chuẩn)	4,424.14	612.7%	Không
Benchmark Gốc	Seasonal Naive (lag 52)	1,775.43	−11.52%	2,294.98	317.6%	Không
Linear Baseline	Lasso với lag features	1,564.00	−22.06%	3,888.46	267.0%	Không
ML Cơ sở	CatBoost (GPU)	1,453.25	−27.57%	2,696.62	741.5%	Lệch 4.07%
ML Cơ sở	LightGBM (CPU)	1,290.87	−35.67%	2,121.34	625.8%	Lệch 4.07%
ML Cơ sở	XGBoost (GPU)	1,264.82	−36.96%	1,785.02	1,063.7%	Lệch 4.07%
Giai đoạn P1	LightGBM L_1 + Zero-Clipping	1,304.64	−34.98%	2,226.32	**486.5**%	Lệch 4.07%
Giai đoạn P2	**Weighted Duo Blend + Multiplier**	**1,264.39**	**−36.98**% (Kỷ lục Test)	1,887.31	974.8%	Lệch 3.81%
Giai đoạn P3	Optuna GroupStats + Super Blend	1,268.98	−36.76%	**1,856.28** (Kỷ lục Val)	941.4%	Lệch 3.81%

5 Kết luận (Conclusion)

5.1 Các Kết luận Rút ra và Đóng góp Kỹ thuật Cốt lõi (Key Technical Takeaways)

Nghiên cứu đã xây dựng thành công một hệ sinh thái dự báo chuỗi thời gian bán lẻ toàn diện từ các mô hình chuẩn mực thống kê (Naive, Seasonal Naive, Moving Average), mô hình tuyến tính có điều chuẩn (Ridge, Lasso) đến các thuật toán học máy dạng bảng tiên tiến (LightGBM, XGBoost, CatBoost). Đặc biệt, thông qua lộ trình cải tiến ba giai đoạn chuyên sâu (P1–P3), bài toán dự báo doanh số bán lẻ quy mô lớn trên 3,331 chuỗi thời gian của tập đoàn Walmart[19] đã được giải quyết với độ chính xác vượt trội.

Từ toàn bộ quá trình nghiên cứu lý thuyết, thiết kế kiến trúc và thực nghiệm định lượng qua nhiều hạt giống ngẫu nhiên (multi-seed), năm bài học kỹ thuật cốt lõi được đúc kết:

1. **Hiểu sâu sắc cấu trúc dữ liệu mang tính quyết định hơn độ phức tạp của thuật toán:** Việc phát hiện ra 20.14% chuỗi thời gian (671 chuỗi) bị đứt gãy lịch sử trong quá trình phân tích khám phá (EDA) và tái tạo thành công khung lưới Descartes liên tục $\mathcal{G} = \mathcal{I} \times \mathcal{T}_{\text{all}}$ (606,270 ô thời gian) là điều kiện tiên quyết giúp các toán tử trễ (y_{t-k}) và toán tử cửa sổ trượt duy trì chính xác khoảng cách bước nhảy thời gian, ngăn chặn hoàn toàn lỗi trôi dạt chỉ mục (Index Shift)[12]. Bên cạnh đó, việc chủ động bóc tách hiện tượng lệch tuần của Lễ Tạ Ơn thành bộ ba đặc trưng trễ an toàn ($\text{lag}_{51}, \text{lag}_{52}, \text{lag}_{53}$) kết hợp biến khoảng cách tuần đã chuyển hóa điểm nghẽn gây nhiễu lớn nhất của chuỗi thời gian thành các đặc trưng dẫn đường mạnh mẽ nhất cho mô hình cây (Ablation C3 cắt giảm tới -39.3% sai số Validation).

2. **Sự đồng bộ mang tính nguyên tắc giữa hàm mất mát tối ưu và thang đo đánh giá:** Kết quả vượt trội của XGBoost trên mốc cơ sở (1,264.82 USD) và sự cải thiện vượt bậc của LightGBM P1 khẳng định tầm quan trọng sống còn của việc lựa chọn hàm mục tiêu: việc tối ưu hóa trực tiếp chuẩn sai số tuyệt đối L_1 (hội tụ về trung vị có điều kiện $\text{Median}[y \mid \mathbf{x}]$) hoàn toàn phù hợp với bản chất toán học của thang đo WMAE, thay vì sử dụng hàm mất mát chuẩn L_2 truyền thống vốn tối ưu kỳ vọng có điều kiện $\mathbb{E}[y \mid \mathbf{x}]$ và rất dễ bị kéo lệch bởi các quan sát ngoại lai cực hạn trong các tuần lễ hội.

3. **Khai thác chiều sâu đặc trưng nghiệp vụ và thống kê nhóm mục tiêu**

(Target Group Statistics): Việc đưa vào 8 đặc trưng thống kê nhóm phân cấp cấp độ Cửa hàng × Phòng ban (Store × Dept) ở giai đoạn P3 (trung bình, trung vị, độ lệch chuẩn, giá trị lớn nhất, nhỏ nhất và tỷ số doanh số hiện tại so với kỳ vọng lịch sử của nhóm) đã cung cấp cho thuật toán GBDT ngữ cảnh phân phối tĩnh mạnh mẽ. Các đặc trưng này cho phép cây quyết định phân tầng chính xác quy mô hoạt động của từng phòng ban mà không làm phức tạp hóa cấu trúc mạng hay yêu cầu các giả định tham số ngặt nghèo, đưa đặc trưng thống kê nhóm lọt vào Top-5 biến quan trọng nhất toàn hệ thống (chiếm 8.32% tổng độ lợi cây).

4. **Giá trị thực tiễn to lớn của các kỹ thuật hậu xử lý (Post-Processing) và co giãn mùa vụ:** Bộ lọc miền giá trị vật lý Zero-Clipping ($\hat{y} = \max(0, \hat{y})$) chứng minh rằng việc áp đặt các ràng buộc nghiệp vụ không âm vào đầu ra của mô hình toán học thuần túy giúp cắt giảm ngay lập tức hơn 400% sai số tương đối MAPE và loại bỏ triệt để các dự báo vô lý trong thực tế quản trị bán lẻ mà không tiêu tốn thêm tài nguyên tính toán. Đồng thời, bộ nhân co giãn Holiday Multiplier ($\alpha = 1.02$) áp dụng chuyên biệt cho 27 ngành hàng nhạy cảm ($\mathcal{D}_{\text{surge}}$) trong tuần Lễ Tạ Ơn (tuần 47) đã khắc phục thành công hạn chế nén biên độ tại các nút lá của thuật toán GBDT, kéo các đỉnh dự báo tiệm cận nhu cầu thực tế trong tuần cao điểm mua sắm Black Friday.

5. **Sức mạnh hiệp đồng của tập hợp mô hình đa dạng (Ensemble Blending) và quy trình thực nghiệm nghiêm ngặt:** Sự kết hợp tối ưu giữa tính chính xác trên chuẩn L_1 của XGBoost và độ phân tán mượt mà của LightGBM thông qua cơ chế hòa trộn lồi (Weighted Duo-Blend ở P2 và Super-Blend ở P3) đã tạo ra giải pháp vượt trội hơn mọi mô hình thành phần đơn lẻ, thiết lập thành tích Test WMAE tối ưu $1{,}264.39 \pm 3.04$ USD (giảm 37.0% so với Moving Average 2,006.54 USD và giảm 28.8% so với Seasonal Naive 1,775.43 USD) với hệ số giải thích phương sai $R^2 = 0.9849$[4]. Toàn bộ hiệu năng được bảo chứng thông qua giao thức kiểm định chéo Rolling Origin CV 4-fold và kiểm thử 3 hạt giống ngẫu nhiên độc lập, bảo đảm tính khái quát hóa và độ ổn định thực chất của mô hình.

5.2 Hạn chế của Nghiên cứu và Hướng Phát triển Tương lai (Limitations and Future Work)

Mặc dù hệ thống mô hình đạt được hiệu năng dự báo ấn tượng và đáp ứng toàn diện các tiêu chí đánh giá khắt khe của bài toán, nghiên cứu vẫn ghi nhận ba hạn chế mang

tính kỹ thuật:

1. **Sự khuyết thiếu dữ liệu ngoại sinh khuyến mãi trong quá khứ:** Dữ liệu năm kênh chiết khấu thương mại (`MarkDown1-5`) bị khuyết hoàn toàn trong gần hai năm đầu (từ 02/2010 đến 10/2011) và chỉ bắt đầu xuất hiện từ tháng 11/2011. Do sự đứt gãy nghiêm trọng này, mô hình cây không thể học trọn vẹn mối quan hệ nhân quả dài hạn giữa các mức giảm giá và độ co giãn của cầu tiêu dùng trong các giai đoạn trước đó, khiến nhóm biến ngoại sinh này không đóng góp tích cực vào việc giảm thiểu sai số WMAE tổng thể.

2. **Giới hạn của giao thức dự báo một bước thời gian (One-step-ahead Horizon):** Việc sử dụng các biến trễ ngắn hạn ($\text{lag}_1, \text{lag}_2, \text{lag}_4$) khai thác doanh số thực tế của các tuần liền trước rất phù hợp cho kịch bản điều hành kho vận tuần kế tiếp. Tuy nhiên, khi mở rộng dự báo dài hạn liên tục 39 tuần cho tập kiểm thử tương lai (`test.csv`) mà không có doanh số quan sát giữa chừng, hệ thống cần được trang bị cơ chế tự quy đệ quy (Recursive Multi-Step) hoặc mô hình hóa trực tiếp đa chân trời (Direct Multi-Horizon)[17] để ngăn chặn sự tích lũy sai số trôi dạt.

Từ các hạn chế trên, ba hướng phát triển tương lai đầy tiềm năng được đề xuất:

- **Dự báo khoảng bất định thông qua Conformal Prediction:** Ứng dụng lý thuyết dự báo phân vị không phân phối (Distribution-Free Conformal Prediction)[2] kết hợp với các mô hình GBDT hiện có nhằm sinh ra các khoảng tin cậy có độ phủ toán học nghiêm ngặt $(1 - \alpha)$, hỗ trợ doanh nghiệp ra quyết định tồn kho tối ưu dưới điều kiện biến động giá cả và thời tiết bất thường.

- **Triển khai chiến lược dự báo tự quy đệ quy và Direct Multi-Horizon GBDT:** Xây dựng hệ thống dự báo hồi quy tự đệ quy có kiểm soát sai số tích lũy (Autoregressive Recursive Forecasting) kết hợp huấn luyện các mô hình GBDT chuyên biệt cho từng chân trời $h \in \{1, 2, \ldots, 39\}$ tuần[17], phục vụ bài toán lập kế hoạch chuỗi cung ứng trung và dài hạn của các tập đoàn bán lẻ.

References

[1] Takuya Akiba, Shotaro Sano, Toshihiko Yanase, Takeru Ohta, and Masanori Koyama. Optuna: A next-generation hyperparameter optimization framework. In *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD)*, pages 2623–2631, 2019. doi: 10.1145/3292500.3330701.

[2] Anastasios N. Angelopoulos and Stephen Bates. A gentle introduction to conformal prediction and distribution-free uncertainty quantification. *arXiv preprint arXiv:2107.07511*, 2021. URL https://arxiv.org/abs/2107.07511.

[3] Abdul Fatir Ansari, Lorenzo Stella, Caner Turkmen, Yuyang Wang, and David Salinas. Chronos: Learning the language of time series. *Transactions on Machine Learning Research*, 2024. URL https://arxiv.org/abs/2403.07815.

[4] Devon K. Barrow and Sven F. Crone. Cross-validation aggregation of neural network ensembles for time series forecasting. *International Journal of Forecasting*, 32(4):1120–1137, 2016. doi: 10.1016/j.ijforecast.2016.01.002.

[5] James Bergstra, Rémi Bardenet, Yoshua Bengio, and Balázs Kégl. Algorithms for hyper-parameter optimization. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 24, pages 2546–2554, 2011.

[6] George E. P. Box and Gwilym M. Jenkins. *Time Series Analysis: Forecasting and Control*. Holden-Day, San Francisco, 1970.

[7] Tianqi Chen and Carlos Guestrin. XGBoost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD)*, pages 785–794, 2016. doi: 10.1145/2939672.2939785.

[8] Jerome H. Friedman. Greedy function approximation: A gradient boosting machine. *Annals of Statistics*, 29(5):1189–1232, 2001. doi: 10.1214/aos/1013203451.

[9] Rob J. Hyndman and George Athanasopoulos. *Forecasting: Principles and Practice*. OTexts, Melbourne, Australia, 2nd edition, 2018. URL https://otexts.com/fpp2/.

[10] Rob J. Hyndman and Anne B. Koehler. Another look at measures of forecast accuracy. *International Journal of Forecasting*, 22(4):679–688, 2006. doi: 10.1016/j.ijforecast.2006.03.001.

[11] Tim Januschowski, Jan Gasthaus, Yuyang Wang, David Salinas, Valentin Flunkert, Michael Bohlke-Schneider, and Laurent Callot. Criteria for classifying forecasting methods. *International Journal of Forecasting*, 36(1):167–177, 2020. doi: 10.1016/j.ijforecast.2019.05.008.

[12] Shachar Kaufman, Saharon Rosset, Claudia Perlich, and Ori Stitelman. Leakage in data mining: Formulation, detection, and avoidance. *ACM Transactions on Knowledge Discovery from Data (TKDD)*, 6(4):1–21, 2012. doi: 10.1145/2382577.2382579.

[13] Guolin Ke, Qi Meng, Thomas Finley, Taifeng Wang, Wei Chen, Weidong Ma, Qiwei Ye, and Tie-Yan Liu. LightGBM: A highly efficient gradient boosting decision tree. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 30, pages 3146–3154, 2017.

[14] Bryan Lim and Stefan Zohren. Time-series forecasting with deep learning: A survey. *Philosophical Transactions of the Royal Society A*, 379(2194):20200209, 2021. doi: 10.1098/rsta.2020.0209.

[15] Liudmila Prokhorenkova, Gleb Gusev, Aleksandr Vorobev, Anna Veronika Dorogush, and Andrey Gulin. CatBoost: Unbiased boosting with categorical features. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 31, pages 6638–6648, 2018.

[16] David Salinas, Valentin Flunkert, Jan Gasthaus, and Tim Januschowski. DeepAR: Probabilistic forecasting with autoregressive recurrent networks. *International Journal of Forecasting*, 36(3):1181–1191, 2020. doi: 10.1016/j.ijforecast.2019.07.001.

[17] Souhaib Ben Taieb, Gianluca Bontempi, Amir F. Atiya, and Antti Sorjamaa. A review and comparison of strategies for multi-step ahead time series forecasting based on the NN5 forecasting competition. *Expert Systems with Applications*, 39(8): 7067–7083, 2012. doi: 10.1016/j.eswa.2012.01.039.

[18] Robert Tibshirani. Regression shrinkage and selection via the lasso. *Journal of the Royal Statistical Society: Series B (Methodological)*, 58(1):267–288, 1996.

[19] Walmart. Walmart recruiting - store sales forecasting: Use historical markdown data to predict store sales. In *Kaggle Competition*, 2014. URL https://www.kaggle.com/competitions/walmart-recruiting-store-sales-forecasting.

[20] Ailing Zeng, Muxi Chen, Lei Zhang, and Qiang Xu. Are transformers effective for time series forecasting? In *Proceedings of the AAAI Conference on Artificial Intelligence (AAAI)*, volume 37, pages 11121–11128, 2023. doi: 10.1609/aaai.v37i9.26317.

Phụ lục (Appendices)

Phụ lục A: Bảng Phân công Công việc và Mức độ Đóng góp Thành viên

Bảng phân công công việc và mức độ đóng góp của mỗi tành viên được tổng hợp tại bảng 5.1 và phần miêu tả dưới đây

Table 5.1: Bảng phân công trách nhiệm và tỷ lệ đóng góp của từng thành viên.

Họ tên học viên	**Mã số học viên**	**Đóng góp**
Đào Duy Đạt	2352223	50%
Nguyễn Hồ Quang Khải	2352538	50%
Tổng cộng		100%

Đào Duy Đạt (2352223):

- Hiện thực các mô hình chuẩn mực cơ sở (Baseline): Naive, Seasonal Naive và Moving Average
- Hiện thực mô hình Linear Baseline (Ridge và Lasso có điều chuẩn với lag features)
- Hiện thực mô hình CatBoost
- Hiện thực mô hình LightGBM
- Biên soạn các phần báo cáo về baseline, mô hình tuyến tính, GBDT, thiết lập thực nghiệm và đối sánh đa seed.

Nguyễn Hồ Quang Khải (2352538):

- Thực hiện phân tích dữ liệu (EDA) và tiền xử lí dữ liệu (chống hiện tượng Index Shift và Data Leakage)
- Hiện thực mô hình XGBoost tối ưu hóa chuẩn L_1
- Hiện thực các giải pháp cải tiến:
  - P1: Bộ lọc miền giá trị vật lý Zero-Clipping.
  - P2: Nhận diện ngành hàng bùng nổ, Thanksgiving Multiplier và Weighted Duo-Blend.
  - P3: Target Group Stats và tối ưu hóa Bayesian Optuna (TPESampler).
- Nghiên cứu và triển khai các thuật toán hòa giải phân cấp (hierarchical)
- Nghiên cứu và triển khai P3 kết hợp với thuật toán hòa giải phân cấp (hierarchical)

- Biên soạn các phần báo cáo về phát biểu bài toán, khung lưới chống rò rỉ, cải tiến P1–P3, thuật toán hòa giải phân cấp và kết luận

Cam kết Liêm chính Học thuật (Academic Integrity Pledge): Nhóm học viên cam kết danh dự rằng toàn bộ mã nguồn trong kho lưu trữ Git (liên kết github: https://github.com/Cocobaut/Time-Series-Forecasting-By-ML) và toàn bộ các số liệu thực nghiệm định lượng trình bày trong báo cáo này là kết quả lao động nghiên cứu thực chất của nhóm, tuyệt đối không sao chép nguyên mẫu từ bất kỳ báo cáo hoặc kho mã nguồn chưa công bố của các nhóm khác. Mọi tài liệu nghiên cứu tham khảo từ các bài báo khoa học quốc tế đều được trích dẫn nguồn gốc tường minh và đầy đủ theo chuẩn học thuật.

Phụ lục B: Khai báo Sử dụng Công cụ Trí tuệ Nhân tạo (AI Tools Declaration)

Dưới đây là các công cụ trí tuệ nhân tạo (AI Tools) mà nhóm triển khai trong suốt quá trình thực thi dự án và được miêu tả tại bảng 5.2

Table 5.2: Khai báo minh bạch về việc sử dụng công cụ AI trong dự án.

Công cụ AI sử dụng	**Hạng mục được hỗ trợ**	**Phạm vi can thiệp và Mô tả chi tiết**
Claude 5.5 Opus	Tái cấu trúc mã nguồn & Quản lý cấu hình đường dẫn	Hỗ trợ rà soát, tái cấu trúc (refactor) và làm sạch mã nguồn; chuẩn hóa quy cách đặt tên biến/hàm, cấu hình lại hệ thống đường dẫn tuyệt đối/tương đối và biến môi trường cho toàn bộ dự án.
Antigravity / Gemini	Nghiên cứu thuật toán, Mã nguồn & Báo cáo	Hỗ trợ tổng hợp, đối chiếu tài liệu học thuật; phân tích và nghiên cứu cơ chế hoạt động của thuật toán; đề xuất các đoạn mã tham khảo (reference snippets); hỗ trợ soạn thảo, diễn đạt nội dung các phần trong báo cáo kỹ thuật.
ChatGPT (GPT-4o) (OpenAI)	Tra cứu tài liệu & Soạn thảo báo cáo	Hỗ trợ tra cứu nhanh kiến thức lý thuyết, tài liệu kỹ thuật liên quan; hỗ trợ phác thảo dàn ý và trau chuốt câu từ trong quá trình soạn thảo nội dung báo cáo.

Xác nhận Quyền tác giả và Trách nhiệm Giải trình Chuyên môn (Accountability Statement): Nhóm học viên long trọng cam kết và khẳng định:

1. Các công cụ AI chỉ đóng vai trò là **phương tiện hỗ trợ kỹ thuật** (tra cứu cú pháp, rà soát ngữ pháp, định dạng văn bản). Công cụ AI **không** thay thế tư duy nghiên cứu của con người.

2. Toàn bộ ý tưởng khoa học cốt lõi, bao gồm:

   - Khung lưới Descartes liên tục giải quyết triệt để lỗi trôi dạt chỉ mục
   - Nguyên lý chống rò rỉ dữ liệu nghiêm ngặt qua toán tử dịch chuyển trễ nhân quả L^1
   - Thuật toán cải tiến mô hình qua 3 giai đoạn P1, P2, P3 và và Thuật toán Hierarchical Reconciliation

- Ý tưởng nhận diện 27 ngành hàng bùng nổ và thuật toán bù co giãn Thanksgiving Multiplier
- Chứng minh giải tích và ứng dụng ma trận ràng buộc $\mathbf{C}$ tăng tốc hòa giải phân cấp MinT hơn 380,000 lần

đều là **sáng kiến độc lập và do chính các thành viên trong nhóm trực tiếp nghiên cứu, phát triển và chứng minh**.

3. Toàn bộ các mô hình thực nghiệm đều được huấn luyện thực tế trên phần cứng máy trạm cá nhân của nhóm (ghi nhận đầy đủ qua log thời gian thực tế và file `results/hardware_info.json`).

4. **Mọi thành viên trong nhóm đều hiểu thấu đáo bản chất, tự tin giải trình và bảo vệ 100% các công thức toán học, thuật toán, tham số cấu hình và từng dòng mã nguồn trong toàn bộ dự án.**

Phụ lục C: Bảng Cấu hình Siêu tham số Tối ưu Chi tiết (Hyperparameter Catalog)

Nhằm đảm bảo khả năng tái lập hoàn hảo kết quả nghiên cứu (Reproducibility), Bảng 5.3 công bố chi tiết toàn bộ các giá trị siêu tham số tối ưu thu được từ quá trình tối ưu hóa Bayesian Optuna (50 trials) và được lưu trữ trực tiếp trong các tệp cấu hình `best_params.json` của hệ thống.

Table 5.3: Danh mục chi tiết bộ siêu tham số tối ưu của các mô hình học máy.

Mô hình	**Tên siêu tham số (Hyperparameter)**	**Giá trị tối ưu xác định**
XGBoost (GPU)	`objective`	`'reg:absoluteerror'` (Hàm mất mát L_1)
	`tree_method`	`'hist'` (Phân nhánh dựa trên histogram)
	`learning_rate` (η)	0.023719
	`max_depth`	10 (Độ sâu tối đa của cây quyết định)
	`subsample`	0.8931 (Tỷ lệ lấy mẫu ngẫu nhiên theo dòng)
	`colsample_bytree`	0.8394 (Tỷ lệ lấy mẫu đặc trưng theo cột)
	`reg_alpha` ($\alpha - L_1$)	0.004215
	`reg_lambda` ($\lambda - L_2$)	0.004215
	`n_estimators`	2,000 (Dừng sớm: 50 rounds trên Validation)
LightGBM (Tuned)	`objective`	`'regression'` (L_2 Loss)
	`boosting_type`	`'gbdt'`
	`learning_rate` (η)	0.057214
	`num_leaves` (N_{leaves})	90 (Số nút lá tối đa trên cây)
	`subsample` (bagging fraction)	0.7953
	`colsample_bytree` (feature fraction)	0.6702
	`reg_alpha`	0.034412
	`reg_lambda`	0.001673
	`min_child_samples`	20
	`n_estimators`	5,000 (Dừng sớm: 100 rounds trên Validation)
LightGBM P3 (Group Stats + Optuna)	`objective`	`'regression_l1'` (L_1 Loss)
	`learning_rate` (η)	0.061339
	`num_leaves` (N_{leaves})	60
	`min_child_samples`	25
	`subsample`	0.85527
	`colsample_bytree`	0.78205
	`reg_alpha`	0.002828
	`reg_lambda`	0.067865
	`n_estimators`	4,000 (Dừng sớm: 100 rounds trên Validation)
CatBoost (GPU)	`loss_function`	`'RMSE'`
	`eval_metric`	`'RMSE'`
	`learning_rate`	0.051324
	`depth`	8 (Độ sâu cây đối xứng Oblivious Tree)
	`subsample`	0.6432
	`l2_leaf_reg`	0.001174
	`random_strength`	0.0301
	`iterations`	2,000 (Dừng sớm: 50 rounds trên Validation)
Linear Lasso	`alpha` (α)	0.001 (Tối ưu theo WMAE Validation)
	`target_scaling`	y/s_i (Doanh số chuẩn hóa theo quy mô chuỗi)
	`max_iter`	2,000 (Hội tụ tolerance: 10^{-4})
Linear Ridge	`alpha` (α)	0.1 (Tối ưu theo WMAE Validation)
	`target_scaling`	y/s_i (Doanh số chuẩn hóa theo quy mô chuỗi)